

Fundamentos de Econometría

Ignacio Lobato

ITAM

- Se busca estudiar la relación de la variable dependiente Y con un vector de variables explicativas X_2, \dots, X_k
- Vector k -variado (Y, X_2, \dots, X_k) con función de densidad conjunta $f(y, x_2, \dots, x_k)$
- Función de distribución condicional de Y dado X_2, \dots, X_k :

$$g(y|x_2, \dots, x_k) = \frac{f(y, x_2, \dots, x_k)}{f_1(x_2, \dots, x_k)}$$

- Donde $f_1(x_2, \dots, x_k) = \int f(y, x_2, \dots, x_k) dy$

- La CEF de Y dado X_2, \dots, X_k es:

$$E(Y|X_2, \dots, X_k) = \int yg(y|x_2, \dots, x_k) dy$$

- La CEF es el mejor predictor de Y dadas las X 's en el sentido de minimizar la esperanza de los errores $U = (Y - h(\bar{X}))$ al cuadrado:

$$\min_h E(Y - h(\bar{X}))^2 = E(U^2)$$

- Se busca la mejor combinación lineal de X_2, \dots, X_k para predecir Y
- Se minimiza de acuerdo al criterio: $\phi(c_1, \dots, c_k) = \sum_{i=1}^N u_i^2$, donde

$$u_i = y_i - (c_1 + c_2 x_{i2} + \dots + c_k x_{ik})$$

- Derivando respecto a c_j :

$$\frac{\partial \phi}{\partial c_j} = \sum_i \left(\frac{\partial u_i^2}{\partial c_j} \right) = \sum_i 2u_i \left(\frac{\partial u_i}{\partial c_j} \right) = -2 \sum_i x_{ij} u_i$$

- Condiciones de primer orden: $\sum_i x_{ij} u_i = 0$

- De las condiciones de primer orden se tiene un sistema de k ecuaciones lineales en c_1, \dots, c_k
- Por simplicidad, adoptamos notación matricial: $X_{n \times k} = (x_1, \dots, x_k)$

$$c_{k \times 1} = (c_1, \dots, c_k)', \quad \phi(c_{k \times 1}) = u' u$$

$$u_{n \times 1} = Y - Xc$$

- Condiciones de primer orden: $X'u=0$
- c^* denota el vector solución

$$X'(Y - Xc^*) = 0, \quad \text{o bien, } X'Xc^* = X'Y$$

- La matriz $Q_{k \times k} = X'X$ es simétrica y tiene como columnas las sumas de cuadrados y productos cruzados de los regresores

Full-rank case

- Q es no singular, invertible, $|Q| \neq 0$
- Sucede cuando $\text{rango}(X) = k$
- $Qc^* = X'Y$ tiene solución única: $b_{k \times 1} = Q^{-1}X'Y = AY$
- Fitted-value vector: $\hat{Y}_{n \times 1} = Xb = XAY = NY$
- Residuales: $e_{n \times 1} = Y - \hat{Y} = (I - N)Y = MY$
- Matriz de proyección: $N_{n \times n} = XA = XQ^{-1}X'$
- $M_{n \times n} = I - N = I - XQ^{-1}X'$
- Matrices M y N son idempotentes:

$$MM = M, \quad NN = N$$

- M y N son ortogonales: $MN = 0$
- Propiedades de las matrices Q, M, N y A en p. 155 de Goldberger

Regresión Clásica

- Se tienen n variables aleatorias (Y_1, \dots, Y_n) con función de densidad conjunta $f(y_1, \dots, y_n)$
- $E(y_i) = \mu_i$, $V(y_i) = \sigma_i^2 = \sigma_{ii}$, $C(y_h, y_i) = \sigma_{hi} = \sigma_{ih}$

$$Y = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}, \quad \mu = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_n \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \sigma_{11} & \cdots & \sigma_{1n} \\ \vdots & \sigma_{hi} & \vdots \\ \sigma_{n1} & \cdots & \sigma_{nn} \end{pmatrix}$$

- Definimos $\epsilon = Y - \mu$, la desviación de y de su media
- $E(\epsilon) = 0$, $E(\epsilon\epsilon') = \Sigma = V(Y) = V(\epsilon)$
- **Def:** la matriz de covarianzas entre 2 vectores aleatorios $\underset{m \times 1}{x}$ y $\underset{n \times 1}{z}$ esta dada por:

$$\underset{m \times n}{C(x, z)} = E \{ [x - E(x)] [z - E(z)]' \}$$

- El elemento (h, i) esta dado por $C(x_h, z_i)$

- **Def:** $z = g + h'Y$ es una función escalar lineal, donde g es un escalar y h es un vector de constantes de $n \times 1$

$$E(z) = g + h'\mu, \quad V(z) = h'E(\epsilon\epsilon')h = h'\sum h$$

- **Def:** $z = g + HY$ es una función vectorial lineal, donde g es un vector $k \times 1$ y H es una matriz $k \times n$ de constantes

$$E(z) = g + H\mu, \quad V(z) = HE(\epsilon\epsilon')H' = H\sum H'$$

- **Teorema:** si Y es un vector aleatorio de dimensión $n \times 1$:

$$E(YY') = \mu\mu' + \Sigma$$

- Escribimos:

$$YY' = (\mu + \epsilon)(\mu + \epsilon)' = \mu\mu' + \mu\epsilon' + \epsilon\mu' + \epsilon\epsilon'$$

- Obteniendo esperanza:

$$E(YY') = \mu\mu' + \Sigma$$

dado que $E(\epsilon) = 0$ y μ es constante

- **Teorema:** para un vector aleatorio Y de dimensión $n \times 1$:

$$E(Y'Y) = \text{tr}\left(\sum\right) + \mu'\mu$$

- Recordemos que para 2 matrices cuadradas A y B , $\text{tr}(AB) = \text{tr}(BA)$
- Un escalar es igual a su traza, escribimos:

$$Y'Y = \text{tr}(Y'Y) = \text{tr}(YY')$$

- Obteniendo esperanza y utilizando el teorema de suma de cuadrados:

$$E(Y'Y) = E(\text{tr}(YY')) = \text{tr}(E(YY')) = \text{tr}\left(\sum + \mu\mu'\right)$$

- Utilizando el operador lineal de la traza:

$$\text{tr}\left(\sum + \mu\mu'\right) = \text{tr}\left(\sum\right) + \text{tr}(\mu\mu') = \text{tr}\left(\sum\right) + \mu'\mu$$

- Entonces: $E(Y'Y) = \text{tr}(\sum) + \mu'\mu$

- **Teorema:** sea $Y' TY$, donde Y es un vector aleatorio de dimensión $n \times 1$ y T es una matriz $n \times n$ de constantes, entonces:

$$E(Y' TY) = \text{tr}\left(T \sum\right) + \mu' T \mu$$

- Escribimos $Y' TY = \text{tr}(TYY')$
- Calculando esperanzas:

$$E(Y' TY) = E(\text{tr}(TYY')) = \text{tr}(TE(YY'))$$

- Del teorema de suma de cuadrados:

$$\text{tr}(TE(YY')) = \text{tr}\left(T\left(\sum + \mu\mu'\right)\right) = \text{tr}\left(T \sum\right) + \text{tr}(T\mu\mu')$$

- Por lo tanto:

$$E(Y' TY) = \text{tr}\left(T \sum\right) + \text{tr}(T\mu\mu') = \text{tr}\left(T \sum\right) + \mu' T \mu$$

- **Teorema:** para un par de vectores de funciones lineales $z_1 = g_1 + H_1 Y$ y $z_2 = g_2 + H_2 Y$, donde g_1 es vector de $m_1 \times 1$, H_1 es matriz de $m_1 \times n$, g_2 es vector de $m_2 \times 1$ y H_2 es matriz de $m_2 \times n$:

$$C(z_1, z_2) = H_1 \sum H_2'$$

- Sea $z_1^* = z_1 - E(z_1) = H_1 \epsilon$ y $z_2^* = z_2 - E(z_2) = H_2 \epsilon$
- Multiplicando, $z_1^* z_2^{*'} = H_1 \epsilon \epsilon' H_2'$, entonces:

$$C(z_1, z_2) = E(z_1^* z_2^{*'}) = H_1 E(\epsilon \epsilon') H_2' = H_1 \sum H_2$$

Regresión Clásica: Supuestos

- Para un vector aleatorio $Y_{n \times 1}$ y una matriz $X_{n \times k} = (x_1, \dots, x_k)$:
- $E(Y) = X'\beta$
- $V(Y) = \sigma^2 I_n$
- X es no estocástica
- $\text{rango}(X) = k$

- Para estimar β , del principio de analogía y dado que $\text{rango}(X) = k$, se propone $b = AY$

$$E(b) = E(AY) = AE(Y) = AX\beta = \beta$$

$$V(b) = V(AY) = AV(Y)A' = A\sigma^2 I A' = \sigma^2 Q^{-1}$$

- En el modelo clásico de regresión, b es el estimador lineal insesgado de β con menor varianza:

$$V(b^*) \geq V(b) \text{ para todo } b^* \text{ tal que } E(b^*) = \beta$$

- b^* es una función lineal de Y , puede escribirse como CY , donde C es alguna matriz no estocástica $k \times n$
 - $E(b^*) = CE(Y) = CE(Y) = CX\beta$
 - $V(b^*) = CV(Y)C' = \sigma^2 CC'$
- Sea $C = A + D$, entonces:
 - $CX = AX + DX = I + DX$
 - $CC' = (A + D)(A + D)' = AA' + DD' + AD' + DA'$
- Para que b^* sea insesgado, debe ser que $CX = I$, lo que implica que $DX = 0$ y $DXQ^{-1} = 0$, es decir, $DA' = AD' = 0$

$$V(b^*) = \sigma^2 (AA' + DD') = V(b) + \sigma^2 DD'$$

- La matriz DD' es positiva semidefinida
- Por lo tanto:

$$V(b^*) \geq V(b)$$

Estimación de σ^2 y $V(b)$

- $e = MY$, por lo tanto $E(e) = ME(Y) = MX\beta = 0$ y $V(e) = MV(Y)M' = \sigma^2 M$
- Del teorema de suma de cuadrados:
 $E(e'e) = \text{tr}(V(e)) + E(e)'E(e) = \sigma^2 \text{tr}(M)$
- $M = I_n - N$, por lo tanto $\text{tr}(M) = n - k$
- Dado lo anterior y el principio de analogía, se propone $\hat{\sigma}^2 = \frac{e'e}{n-k}$ para estimar σ^2
- $\hat{\sigma}^2$ es insesgado:

$$E(\hat{\sigma}^2) = E\left(\frac{e'e}{n-k}\right) = \frac{\sigma^2(n-k)}{n-k} = \sigma^2$$

- Finalmente, se usa $\hat{V}(b) = \hat{\sigma}^2 Q^{-1}$ para estimar $V(b)$

- Sea (Y, x_2, \dots, x_k) un vector aleatorio con función de densidad conjunta $f(Y, x_2, \dots, x_k)$
- $E(Y) = \mu_y$, $V(Y) = \sigma^2$, $C(x_h, x_j) = \sigma_{hj}$
- Se asume función de esperanza condicional lineal y varianza constante:

$$E(Y|x_2, \dots, x_k) = \beta_1 + \beta_2 x_2 + \dots + \beta_k x_k$$

$$V(Y|x_2, \dots, x_k) = \sigma^2$$

- Tomando $x = (1, x_2, \dots, x_k)'$, y $\beta = (\beta_1, \dots, \beta_k)'$, se expresa lo anterior como $E(Y|x) = x'\beta$ y $V(Y|x) = \sigma^2$

Estimación de Funciones Lineales de β

- Se desea estimar $\theta = h'\beta$, h es un vector de constantes de dimensión $k \times 1$
- Del principio de analogía, se utiliza $\hat{\theta}_n = h'b$
- $\hat{\theta}_n$ es una función lineal de y : $\hat{\theta}_n = h'b = h'AY = w'Y$
- $\hat{\theta}_n$ es insesgado:

$$E(\hat{\theta}_n) = h'E(b) = h'\beta = \theta$$

- De las propiedades de la varianza:

$$V(\hat{\theta}_n) = h'V(b)h = \sigma^2 h'Q^{-1}h$$

- Para cualquier otro estimador de θ : $t^* = w^* Y$, donde w^* es un vector de constantes de $n \times 1$:

$$E(t^*) = w^{*'} X \beta, \quad V(t^*) = \sigma^2 w^{*'} w^*$$

- t^* es insesgado $\Leftrightarrow w^{*'} X = h'$
- En ese caso, $h' Q^{-1} h = w^{*'} X Q^{-1} X' w^* = w^{*'} N w^*$
- Reescribimos entonces $V(\hat{\theta}_n) = \sigma^2 h' Q^{-1} h = \sigma^2 w^{*'} N w^*$

$$V(t^*) - V(\hat{\theta}_n) = \sigma^2 w^{*'} M w^* \geq 0$$

- $\hat{\theta}_n$ es el estimador lineal insesgado de menor varianza
- El error estándar de $\hat{\theta}_n$ es $\hat{\sigma}_t = \hat{\sigma} \sqrt{(h' Q^{-1} h)}$

- Para estimar $\mu_i = E(y_i) = x_i'\beta$, del principio de analogía se utiliza $\hat{y}_i = x_i'b$

$$E(\hat{y}_i) = \mu_i, \quad V(\hat{y}_i) = \sigma^2 x_i' Q^{-1} x_i$$

- Se desea estimar $\mu_0 = x_0'\beta$, donde x_0 es algún vector de dimensión $k \times 1$
- Del principio de analogía, $\hat{\mu}_0 = x_0'b$

$$E(\hat{\mu}_0) = \mu_0, \quad V(\hat{\mu}_0) = \sigma^2 x_0' Q^{-1} x_0$$

- El error estándar de $\hat{\mu}_0$ es $\hat{\sigma} \sqrt{(x_0' Q^{-1} x_0)}$

- El objetivo es predecir el valor de y_0
- Si β fuera conocido, la predicción sería $\mu_0 = x_0' \beta$, y el error $\epsilon_0 = y_0 - \mu_0$

$$E(\epsilon_0) = 0, \quad V(\epsilon_0) = E(\epsilon_0^2) = \sigma^2$$

- En general β no es conocido, pero es estimado con b
- El predictor será $\hat{\mu}_0 = x_0' b$, con error de predicción $u = y_0 - \hat{\mu}_0$

$$\begin{aligned} E(u) &= 0, \quad V(u) = V(y_0) + V(\hat{\mu}_0) - 2C(y_0, \hat{\mu}_0) \\ &= \sigma^2 (1 + x_0' Q^{-1} x_0) \end{aligned}$$

- $C(y_0, \hat{\mu}_0) = 0$ porque y_0 es independiente de la muestra
- El error estándar de $\hat{\mu}_0$ es $\hat{\sigma} \sqrt{(1 + x_0' Q^{-1} x_0)}$

- Se reporta una medida para observar que tan bien ajusta el modelo lineal
- Recordemos que:

$$Y = \hat{Y} + e \Rightarrow Y'Y = (\hat{Y} + e)'(\hat{Y} + e) = \hat{Y}'\hat{Y} + e'e$$

algebraicamente:

$$\sum_i y_i^2 = \sum_i \hat{y}_i^2 + \sum_i e_i^2$$

- También tenemos:

$$\sum_i y_i = \sum_i \hat{y}_i + \sum_i e_i \Rightarrow \bar{Y} = \bar{\hat{Y}} + \bar{e}$$

Coefficiente de Determinación

- Si $\bar{e} = 0$, $\bar{Y} = \bar{\hat{Y}} \Rightarrow n\bar{Y}^2 = n\bar{\hat{Y}}^2$, y restando este resultado a la ecuación anterior:

$$\sum_i (y_i - \bar{Y})^2 = \sum_i (\hat{y}_i - \bar{Y})^2 + \sum_i e_i^2$$

- Definimos ahora el coeficiente de determinación:

$$R_n^2 = \frac{\sum_i (\hat{y}_i - \bar{Y})^2}{\sum_i (y_i - \bar{Y})^2} = 1 - \frac{\sum_i e_i^2}{\sum_i (y_i - \bar{Y})^2}$$

$$0 \leq R_n^2 \leq 1$$

- R_n^2 mide la proporción de la varianza de Y explicada por el predictor lineal

Coeficiente de Determinación

- Intuitivamente, R_n^2 mide que tan bien ajustados están los datos a la regresión
- Si $R_n^2 = 1$, el ajuste es perfecto, todas las y 's pertenecen a una función lineal de las x 's:

$$R_n^2 = 1 \Leftrightarrow \sum_i e_i^2 = 0 \Leftrightarrow e'e = 0 \Leftrightarrow e = 0 \Leftrightarrow Y = X\beta$$

- Si $R_n^2 = 0$, el mejor predictor lineal es horizontal:

$$R_n^2 = 0 \Leftrightarrow \sum_i (\hat{y}_i - \bar{Y})^2 = 0 \Leftrightarrow \hat{y}_i = \bar{Y}$$

Coeficiente de Determinación (apuntes)

- Solo habrá coeficiente de determinación cuando exista intercepto, es decir:
 - Una columna de X debe ser un vector de 1's
 - Existe una combinación lineal de columnas de X igual a un vector de 1's
- R_n^2 suele aumentar cuando se agregan variables explicativas

Coeficiente de Determinación Ajustado

- Se introduce el coeficiente de determinación ajustado \bar{R}_n^2

-

$$1 - \bar{R}_n^2 = \frac{(n-1)(1 - R_n^2)}{n - k}$$

- Despejando \bar{R}_n^2 :

$$\bar{R}_n^2 = 1 - \frac{\sum_i e_i^2 / (n - k)}{\sum_i (y_i - \bar{Y})^2 / (n - 1)}$$

- \bar{R}_n^2 aumenta la proporción no explicada y disminuye la proporción explicada