

Fundamentos de Econometría

Ignacio Lobato

ITAM

- Los distintos eventos que pueden ocurrir son identificados en su totalidad y a estos se les asigna un valor mediante una variable aleatoria X (X es una variable aleatoria).
- X al ser una variable aleatoria es caracterizada por su dominio y su densidad.
- En particular distinguiremos dos casos: El discreto y el continuo

- En el caso discreto el nro. de resultados posibles es finito o numerable (contable). Se compila una lista de valores de x ordenadas: x_1, x_2, x_3 .
.
- Convencionalmente se ordenan los valores de menor a mayor y se asignan probabilidades con la función $f(x)$, con las siguientes propiedades:
 - $f(x) \geq 0$ en todo punto
 - $f(x) = 0$ excepto en los puntos de masa x_1, x_2, \dots
 - $\sum_i (f(x_i)) = 1$
.
- Existen varios ejemplos de funciones de distribución probabilística discretas.

- Distribución de Bernoulli

$$f(x) = p^x(1 - p)^{(1-x)}$$

para $x=0,1$

- Distribución Uniforme Discreta con parámetro N (entero positivo)

$$f(x) = 1/N$$

para $x=1,2,\dots,N$

- Distribución Binomial

$$f(x) = \frac{n!}{x!(n-x)!} p^x (1-p)^{n-x}$$

para $x=1,2,\dots,N$

El Caso Continuo

- Hay un continuo de valores que la variable aleatoria X puede tomar, aquí las probabilidades ya no se calculan puntualmente sino para un intervalo.
- La asignación de probabilidades se realiza a través de la función de densidad que satisface lo siguiente:

$$f(x) \geq 0$$

en todo punto y

$$\int_{-\infty}^{\infty} f(x) dx = 1$$

- Así para cualquier par de números a, b con $a \leq b$

$$Pr(a \leq x \leq b) = \int_a^b f(x) dx$$

- De esta manera definimos la función de distribución acumulada (cdf) como:

$$F(x) = \int_{-\infty}^x f(t)dt$$

Es decir, $F(x)$ denota

$$Pr(X \leq x) \tag{1}$$

- La cdf presenta las siguientes propiedades:
 - 1) $F(-\infty) = 0$
 - 2) $F(\cdot)$ es monotónicamente no decreciente.
 - 3) $F(\cdot)$ es diferenciable en cualquier punto por su definición.
- Note lo siguiente:

$$Pr(a \leq X \leq b) = \int_a^b f(x) = \int_{-\infty}^b f(x) - \int_{-\infty}^a f(x) = F(b) - F(a)$$

- Algunos ejemplos de funciones de distribución continua:

1) Rectangular o Uniformemente Continua en el intervalo $[a, b]$. La pdf es:

$$f(x) = 1/(b - a)$$

para $a \leq x \leq b$

De esta manera tendríamos que:

$$F(x) = \begin{cases} 0 & \text{si } x < a \\ (x-a)/(b-a) & \text{si } a \leq x \leq b \\ 1 & \text{si } b < x \end{cases}$$

2) Exponencial con parámetro $\lambda > 0$. La pdf es $f(x) = \lambda e^{-\lambda x}$ para $x > 0$:

Entonces tendríamos que:

$$F(x) = \begin{cases} 0 & \text{si } x \leq 0 \\ 1 - e^{-\lambda x} & \text{si } x > 0 \end{cases}$$

3) Normal Estándar. La pdf es $\phi(x)$ y denotamos la cdf por $\Phi(x)$ donde:

$$\phi(x) = (2\pi)^{-0,5} \exp(-x^2/2)$$

4) Logística Estándar. La pdf es:

$$f(x) = e^x / (1 + e^x)^2$$

De esta manera:

$$F(x) = e^x / (1 + e^x)$$

5) Potencia en el intervalo $[0, 1]$ con parámetro $\theta > 0$. La pdf es:

$$f(x) = \theta x^{\theta-1}$$

para $0 \leq x \leq 1$ con densidad cero en cualquier otro punto. De esta manera, tenemos que:

$$F(x) = \begin{cases} 0 & \text{si } x < 0 \\ x^\theta & \text{si } 0 \leq x \leq 1 \\ 1 & \text{si } x > 1 \end{cases}$$

Esperanzas en el caso Univariado

- La media en una distribución de probabilidad es llamada La Esperanza o Valor Esperado.
- Supongamos que la variable aleatoria X tiene una función de distribución o de densidad $f(x)$, $X \sim f(x)$.
- Luego la esperanza de X es definida como:

$$E(X) = \begin{cases} \sum_i x_i f(x_i) & \text{en el caso discreto} \\ \int_{-\infty}^{\infty} x f(x) dx & \text{en el caso continuo} \end{cases}$$

- De esta manera, dada $Z=h(x)$, podemos calcular la esperanza de dicha variable aleatoria utilizando la función de distribución de X .

$$E(Z) = \begin{cases} \sum_i h(x_i) f(x_i) & \text{en el caso discreto} \\ \int_{-\infty}^{\infty} h(x) f(x) dx & \text{en el caso continuo} \end{cases}$$

Momentos Centrados y No Centrados

- Sea $X^* = X - E(X) = X - \mu$.
- $E(X^r) = \mu'_r$ es el momento r-ésimo no centrado de X.
- $E(X^{*r}) = \mu_r$ es el momento r-ésimo centrado en la media de X
- Cada momento da información sobre la distribución de X. Por ejemplo tendremos que si $r=1$, $E(X) = \mu$ y $E(X^*) = 0$.
- Si tomamos $r=2$, tendremos $E(X^2)$ y $E(X^{*2}) = \sigma^2$ es la varianza de X.

Teoremas Usando Esperanzas

- **T1:** Sea X una variable aleatoria y a, b dos constantes cualesquiera, tales que $Z = a + bX$. Entonces se cumple que:

$$E(Z) = a + bE(X)$$

y

$$V(Z) = b^2 V(X)$$

- **T2:** La Varianza de una variable aleatoria se puede calcular como:

$$V(X) = E(X^2) - E^2(X)$$

Teoremas Usando Esperanzas

- **T3:** (Error Cuadrático Medio): Sea c cualquier constante. Luego el error cuadrático medio de una variable X respecto a c es:

$$E(X - c)^2 = \sigma^2 + (c - \mu)^2$$

Demostración:

Podemos escribir $(X - c) = (X - \mu) - (c - \mu) = X^* - (c - \mu)$.

Luego:

$$(X - c)^2 = X^{*2} + (c - \mu)^2 - 2(c - \mu)X^*$$

Usando T1:

$$E(X - c)^2 = E(X^{*2}) + (c - \mu)^2 - 2(c - \mu)E(X^*)$$

Como $E(X^{*2}) = \sigma^2$ y $E(X^*) = 0$, tenemos que:

$$E(X - c)^2 = \sigma^2 + (c - \mu)^2$$

- **T4 (Error Cuadrático Mínimo):** El valor que minimiza $E(X - c)^2$ es μ .

Demostración: Utilizando el T3, tenemos que:

$$E(X - c)^2 = \sigma^2 + (c - \mu)^2$$

Pero $(c - \mu)^2 \geq 0$ con igualdad sí y solo sí $c = \mu$

- Suponemos que la distribución de la variable aleatoria X es conocida ($f(x)$ conocida) y queremos predecir el valor de X a partir de una constante c como predictor.
- Suponemos que nuestro criterio para evaluar la calidad del predictor es el cuadrático medio a través de su minimización.
- Es decir queremos minimizar $E(U^2)$ con $U = (X - c)$.
- Del T4, se sabe que c^* es μ y a partir de ello, $E(U^2) = \sigma^2$.
- A partir de ello, sea $\epsilon = X - \mu$, de lo cual se observa que $E(\epsilon) = 0$ y $E(\epsilon^2) = \sigma^2$.
- Cuando la esperanza del error de predicción de un predictor es cero, decimos que dicho predictor es insesgado (μ es insesgado).

- **Desigualdad de Markov:** Si Y es una variable aleatoria no-negativa; es decir, $Pr(Y < 0) = 0$, y k es cualquier constante positiva, luego $Pr(Y \geq k) \leq E(Y)/k$.

Demostración (para el caso continuo):

$$E(Y) = \int_0^{\infty} yf(y)dy = \int_0^k yf(y)dy + \int_k^{\infty} yf(y)dy = a + b$$

Ahora como $a \geq 0$, $E(Y) \geq b$. También

$b \geq k \int_k^{\infty} f(y)dy = kPr(Y \geq k)$, tenemos que $E(Y) \geq kPr(Y \geq k)$.

- **Desigualdad de Chebychev 1:** Si X es una variable aleatoria, c es cualquier constante, y d es una constante positiva, luego:

$$Pr(|X - c| \geq d) \leq E(x - c)^2 / d^2$$

Demostración:

Sea $Y = (X - c)^2$ una variable aleatoria no negativa. Así:

$$|X - c| \geq d \leftrightarrow Y \geq d^2$$

De esta manera, haciendo $k = d^2$ y aplicando la desigualdad de Markov tenemos que:

$$E(Y) \geq d^2 Pr(Y \geq d^2)$$

- **Desigualdad de Chebychev 2:** Si X es una variable aleatoria con $E(X) = \mu$ y varianza $V(X) = \sigma^2$, y d es cualquier constante positiva, entonces:

$$Pr(|X - \mu| \geq d) \leq \sigma^2/d^2$$

Demostración: Aplicar la Desigualdad de Chebychev 1 con $c = \mu$.

- **Desigualdad de Jensen :** Si $Y = h(X)$ es cóncava y $E(X) = \mu$, entonces: $E(Y) \leq h(\mu)$.

Distribuciones de Probabilidad Bivariadas

- Para estudiar las relaciones entre variables necesitamos más de una variable en las distribuciones de probabilidad. Se detalla aquí el caso bivariado.
- Los resultados son distinguidos por los valores de un par de variables aleatorias X y Y . Nos referiremos a (X,Y) como un vector aleatorio.
- Al igual que en el caso univariado, tendremos el caso discreto y el caso continuo.

Distribuciones de Probabilidad Bivariadas (Caso Discreto)

- Los valores que toman X y Y son finitos o numerables. Así podemos distinguir entre los distintos pares que denotan los valores tomados por X y Y .
- Los puntos enlistados son llamados puntos de masa. Asimismo, la función $f(x,y)$ es llamada la función de masa de probabilidad conjunta y satisface las siguientes propiedades:
 - $f(x,y) \geq 0$ en todo punto y $f(x,y) > 0$ solo en los puntos de masa.
 - $\sum_i \sum_j f(x_i, y_j) = 1$
- De esta manera $\Pr(X=x, Y=y)=f(x,y)$.

Distribuciones de Probabilidad Bivariadas (Caso Continuo)

- Hay un continuo de valores posibles que pueden tomar X y Y. Así hay un continuo bidimensional de valores que puede tomar el par (X,Y).
- La función $f(x,y)$ es llamada la función de densidad de probabilidad conjunta, la cual satisface las siguientes propiedades:
 - $f(x,y) \geq 0$ en cualquier punto.
 - $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x,y) dx dy = 1$
- De esta manera, tenemos que para cualquier $a \leq b, c \leq d$:

$$Pr(a \leq X \leq b, c \leq Y \leq d) = \int_a^b \int_c^d f(x,y) dy dx$$

Distribuciones Marginales (Caso Discreto)

- Sean dos variables aleatorias X y Y . La distribución marginal de X denota la probabilidad de que X tome un determinado valor independientemente de los valores que tome Y .
- Sea $A = \{X = x\}$ y $A_j = \{X = x, Y = y_j\}$ para $j = 1, 2, \dots$. Nótese que $A = \bigcup_j A_j$ que es una unión disjunta de eventos.
- Así calculamos:
$$Pr(X = x) = Pr(A) = \sum_j Pr(A_j) = \sum_j f(x, y_j) = f_1(x)$$
- Esta nueva función $f_1(x)$ es llamada la función de distribución marginal de X . Note que $f_1(x) \geq 0$ en cualquier punto y $f_1(x) > 0$ solo en los puntos de masa o enlistados.
- Por otro lado, se tiene que $\sum_i f_1(x_i) = \sum_i [\sum_j f(x_i, y_j)] = f_1(x)$
- Lo mismo aplicaría en el caso de la variable aleatoria Y .

Distribuciones Marginales (Caso Continuo)

- Sea $A = \{a \leq X \leq b\} = \{a \leq X \leq b, -\infty \leq Y \leq \infty\}$.
- Luego $Pr(a \leq X \leq b) = Pr(A) = \int_a^b \int_{-\infty}^{\infty} f(x, y) dy dx = \int_a^b f_1(x) dx$.
- Es decir: $f_1(x) = \int_{-\infty}^{\infty} f(x, y) dy$ a la cual se le llama la función de densidad marginal de X .
- Nótese que $f_1(x) \geq 0$ en cualquier punto y que $\int_{-\infty}^{\infty} f_1(x) dx = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dy dx = 1$. Por lo tanto, $f_1(x)$ actúa como una función de densidad univariada.
- Lo mismo aplicaría para el caso de la variable aleatoria Y .

Distribuciones Condicionales (Caso Discreto)

- Sea $A = \{X = x\}$, $B = \{Y = y\}$.
- Por probabilidades se sabe que $Pr(A \setminus B) = Pr(A \cap B) / Pr(B)$ siempre que $Pr(B) > 0$.
- Entonces en el caso discreto tendríamos que $Pr(A \cap B) = f(x, y)$ y $Pr(B) = f_2(y)$.
- Entonces $Pr(A/B) = f(x, y) / f_2(y) = g_1(x/y)$.
- $g_1(x/y)$ es llamada la función de distribución (masa) condicional de X dada $Y=y$.
- Note que $\sum_i g_1(x_i/y) = \sum_i [f(x_i, y) / f_2(y)] = [\sum_i f(x_i, y)] / f_2(y) = f_2(y) / f_2(y) = 1$.

Distribuciones Condicionales (Caso Continuo)

- Análogamente al caso anterior, para cada y tal que $f_2(y) \neq 0$, definimos la función: $g_1(x/y) = f(x, y)/f_2(y)$, dejando indefinido $g_1(. / y)$ indefinido en otros puntos, esta función es llamada la función de densidad de X dado $Y=y$.
- Se puede ver que $f(x/y) \geq 0$ en cualquier punto y que:

$$\begin{aligned}\int_{-\infty}^{\infty} g_1(x/y) dx &= \int_{-\infty}^{\infty} [f(x, y)/f_2(y)] dx = [\int_{-\infty}^{\infty} f(x, y) dx] / f_2(y) \\ &= f_2(y) / f_2(y) = 1\end{aligned}$$

Distribuciones Condicionales con un Nro. finito de Variables

- Sean $X_1, X_2, X_3 \dots X_n$ una colección de n variables aleatorias con $n \in \mathbb{N}$.
- Podemos expresar las funciones de densidad conjunta en términos de las densidades condicionales de la siguiente manera:

$$\begin{aligned} f(x_1, x_2, x_3, \dots, x_n) &= f(x_1/x_2, x_3, \dots, x_n) * f(x_2, x_3, \dots, x_n) \\ &= f(x_1/x_2, x_3, \dots, x_n) * f(x_2/x_3, x_4, \dots, x_n) * f(x_3, x_4, \dots, x_n) \\ &= f(x_1/x_2, x_3, \dots, x_n) * f(x_2/x_3, x_4, \dots, x_n) * f(x_3/x_4, x_5, \dots, x_n) * f(x_4, \dots, x_n) \\ &= f(x_1/x_2, \dots, x_n) * f(x_2/x_3, \dots, x_n) * \dots * f(x_{n-1}/x_n) * f(x_n) \end{aligned}$$

- Es decir, podemos expresar la función de densidad conjunta como un producto sucesivo de densidades condicionales.