

# Fundamentos de Econometría

Ignacio Lobato

**ITAM**

- En el capítulo anterior estudiamos la estimación de parámetros en contextos en los cuales no se conoce la población.
- En esta sección, estudiaremos el caso en el cual la forma de la distribución poblacional es conocida, excepto por algunos parámetros que nos interesa estimar.
- Supongamos que la variable aleatoria  $Y$  tiene como densidad poblacional a  $f(Y; \theta)$ , donde la función es conocida excepto por el parámetro  $\theta$ .
- En las siguientes secciones definiremos algunas variables para poder estimar nuestro parámetro de interés  $\theta$ .

# La Función de Verosimilitud y el Score

- Dos variables importantes en esta sección serán la función de verosimilitud y la variable de score.

**Log-Likelihood:** Es el logaritmo de  $f(y; \theta)$ :

$$L = \log(f(Y; \theta)) = L(Y, \theta);$$

**Score:** Se define como la derivada del log-likelihood:

$$Z = \partial \log(f(Y; \theta)) / \partial \theta = \partial L / \partial \theta = Z(Y; \theta)$$

- Definiendo estas variables tendremos los siguientes resultados: 1) el valor esperado del score es cero (ZES rule) y 2) la desigualdad de Cramér-Rao (CRI).

- Este resultado señala que el valor esperado de la variable de score es cero.

**Demostración:** Asumiremos que la variable aleatoria  $Y$  es continua.

$$E(Z) = \int z(y; \theta) f(y; \theta) dy = \int (zf) dy$$

como  $f(y; \theta)$  es una función de densidad, debe cumplirse que:

$$\int f(y, \theta) dy = 1 \quad \text{para todo } \theta$$

Diferenciando en ambos lados respecto a  $\theta$ :

$$\int (\partial f(y, \theta) / \partial \theta) dy = 0$$

Y note que:

$$\partial f / \partial \theta = (\partial \log f / \partial \theta) f = z(y; \theta) f = zf,$$

Por lo tanto:  $\int z f dy = 0$

# Desigualdad de Cramér-Rao (CRI)

- **Desigualdad de Cramér-Rao (CRI):** En una muestra aleatoria de tamaño  $n$ , de una población caracterizada por  $f(y; \theta)$ , si  $T = h(Y_1, \dots, Y_n)$  y  $E(T) = \theta \forall \theta$ , entonces:

$$V(T) \geq 1/[nV(Z)]$$

**Demostración:** Primero considere el caso  $n = 1$ . Aquí  $T = h(Y)$  con  $E(T) = \theta \forall \theta$ . Esto es:

$$\int h(y)f(y; \theta)dy = \theta \quad \forall \theta$$

Diferenciando ambos lados:

$$\int h(y)zf dy = 1, \quad \text{que significa} \quad E(TZ) = 1$$

Como sabemos que  $E(Z) = 0$ , entonces  $C(T, Z) = 1$ .

# Desigualdad de Cramér-Rao (CRI)

De la desigualdad de Cauchy-Schwarz, sabemos que:

$$V(T)V(Z) \geq C^2(T, Z) = 1$$

Por lo tanto:

$$V(T) \geq 1/V(Z)$$

Lo cual es la CRI para  $n=1$ . Para el caso  $n > 1$ , sea  $g = g_n(y_1, \dots, y_n)$  la distribución conjunta de la muestra aleatoria.

Aquí  $T = h(Y_1, \dots, Y_n)$  con  $E(T) = \theta \forall \theta$ . Esto es:

$$\int \dots \int h(y_1, \dots, y_n) g_n(y_1, \dots, y_n; \theta) dy_n \dots dy_1 = \theta$$

Diferenciando ambos lados:

$$\int \dots \int h(\partial g / \partial \theta) dy_n \dots dy_1 = 1$$

# Desigualdad de Cramér-Rao (CRI)

Además:

$$\partial g / \partial \theta = (\partial \log(g) / \partial \theta) g, \quad \text{y} \quad g = \prod_{i=1}^n f(y_i; \theta),$$

Entonces,

$$\log(g) = \sum_i \log f(y_i; \theta) = \sum_i \log f_i$$

Así:

$$\partial \log(g) / \partial \theta = \sum_i (\partial \log f_i / \partial \theta) = \sum_i z(y_i, \theta) = \sum_i z_i = n \bar{Z}$$

Entonces,

$$\int \dots \int h n \bar{Z} g dy_n \dots dy_1 = 1,$$

# Desigualdad de Cramér-Rao (CRI)

Por lo tanto:

$$E(Tn\bar{Z}) = 1$$

y como  $E(\bar{Z}) = E(Z) = 0$ , entonces:

$$C(\bar{Z}, T) = 1/n$$

Luego usando la Desigualdad de Cauchy-Schwarz:

$$V(T)V(\bar{Z}) \geq \frac{1}{n^2}$$

y utilizando que  $V(\bar{Z}) = V(Z)/n$ , tenemos que:

$$V(T) \geq \frac{1}{nV(Z)}$$



# Desigualdad de Cramér-Rao (CRI)

- La CRI no nos provee de un estimador directamente, pero establece un estándar a partir del cual los estimadores insesgados deben ser evaluados.
- Por ejemplo, si encontráramos un estimador insesgado  $T$  con  $V(T) = 1/nV(Z)$ , podemos detener la búsqueda de un mejor estimador insesgado.

- Existe otra forma de plantear la CRI, definiendo lo que se conoce como la **Variable de Información**, entendida como:

$$W = -\partial Z / \partial \theta = -\partial^2 \log f / \partial \theta^2$$

A partir de esta definición, se establece el siguiente resultado:

**La Regla de Información:** La esperanza de la variable de información es igual a la varianza del score.

**Demostración:** Sabemos que  $E(Z) = 0 = \int z f dy$ . Diferenciando respecto a  $\theta$ :

$$\int (\partial z f / \partial \theta) dy = 0$$

Además,

$$\begin{aligned} \partial(zf) / \partial \theta &= z(\partial f / \partial \theta) + (\partial z / \partial \theta)f = z(\partial \log f / \partial \theta)f - wf \\ &= z^2 f - wf = (z^2 - w)f \end{aligned}$$

Entonces tenemos que:

$$\int (z^2 - w) f dy = 0 = E(Z^2 - W)$$

Por lo tanto:

$$E(Z^2) = V(Z) = E(W)$$

- Otra función que tiene la ZES es proveer un estimador para  $\theta$ .
- Supongamos que tenemos una distribución conocida  $f(y; \theta)$  excepto por el parámetro  $\theta$ . Sea la variable de score  $Z = z(y; \theta)$ . Como  $E(Z) = 0$ , podemos caracterizar  $\theta$  como el valor  $c$  que satisface  $E[z(Y, c)] = 0$ .
- Por el principio de analogía, podemos estimar  $\theta$  resolviendo:

$$(1/n) \sum_i z(y_i; c) = 0$$

Entonces el estimador ZES se obtiene resolviendo  $\sum_i \hat{Z}_i = 0$ .

# Estimación por Máxima Verosimilitud

- Existe otro enfoque (más conocido), que produce el mismo estimador dado por la regla ZES. Este es el de Máxima Verosimilitud (ML).
- Considere una población en la cual la variable aleatoria  $Y$  tiene como función de distribución a  $f(y; \theta)$ , con la función  $f$  conocida pero con  $\theta$  desconocido.
- Bajo una muestra aleatoria de tamaño  $n$  se tendría como densidad conjunta:

$$\mathcal{L} = g_n(y_1, \dots, y_n; \theta) = \prod_i f(y_i; \theta)$$

A esta función se le llamará función de verosimilitud para  $\theta$ .

- El estimador de Máxima Verosimilitud (ML) para  $\theta$  es el valor para  $\theta$  que maximiza  $\mathcal{L}$  en la muestra. Además note que si  $\mathcal{L}$  es maximizado, su logaritmo también lo está:

$$\log \mathcal{L} = \sum_i \log(f(y_i; \theta)) = \sum_i L_i$$

Diferenciando respecto a  $\theta$  obtenemos:

$$\partial \log \mathcal{L} / \partial \theta = \sum_i \partial L_i / \partial \theta = \sum_i Z_i = \sum_i z(Y_i; \theta).$$

E igualando a cero, se tiene que el estimador de ML resuelve:

$$\sum_i z(y_i; T) = 0$$

A partir de esto último, observe que el estimador por ML es equivalente al obtenido por la regla ZES.

# Ejemplo

- Supongamos que  $Y \sim \text{Bernoulli}(\theta)$ . Entonces:

$$Z = (Y - \theta)/[\theta(1 - \theta)]$$

Entonces las CPO nos dan:

$$\sum_i \hat{Z}_i = \sum_i (Y_i - T)/[T(1 - T)] = 0,$$

Por lo tanto:

$$\sum_i Y_i = nT \quad \text{entonces} \quad T = \bar{Y}$$

# Propiedades del Estimador por ML

- Existe otra analogía que conduce directamente a la maximización del logaritmo de la función de verosimilitud.
- $\theta$  puede ser caracterizado en la población como el valor  $c$  que maximiza la esperanza de la log-verosimilitud. Ahora considere:

$$D(c) = \log f(y; c) - \log(f; \theta) = \log(f(y; c)/f(y; \theta))$$

Como el logaritmo es una función cóncava, por la desigualdad de Jensen tendremos que:

$$E[D(c)] \leq \log E[f(y; c)/f(y; \theta)]$$

Con igualdad si  $c = \theta$  pero

$$E[f(y; c)/f(y; \theta)] = \int [f(y; c)/f(y; \theta)] f(y; \theta) dy = \int f(y; c) dy = 1,$$



- Entonces tenemos que:

$$E[D(c)] \leq \log(1) = 0$$

Con igualdad si  $c = \theta$ . Esto nos dice que  $\theta$  es el valor para  $c$  que maximiza la media de la log-verosimilitud.

- La ventaja de este enfoque adicional es que este resuelve el caso donde las CPO tienen múltiples soluciones, los cuales ocurren, por ejemplo, en los casos no lineales.
- Este problema de elección es resuelto tomando la solución que da un máximo global.

- Si consideramos una muestra aleatoria de una población cuya variable de Score es  $Z = \partial \log f(y; \theta) / \partial \theta$  y cuya variable de información es  $W = -\partial Z / \partial \theta$ , entonces si  $T$  es el estimador por ML de  $\theta$  se cumple que:

$$T \xrightarrow{P} \theta,$$

$$\sqrt{n}(T - \theta) \xrightarrow{d} N(0, \phi^2) \quad \text{donde} \quad \phi^2 = 1/V(Z) = 1/E(W),$$

$$T \xrightarrow{d} N(\theta, \phi^2/n),$$

$T$  es un estimador BAN de  $\theta$

- Otra propiedad interesante del estimador por ML es la **invarianza**: Si  $\alpha = h(\theta)$  es una función monótona de  $\theta$  y  $T$  es el estimador por ML de  $\theta$ , entonces  $A = h(T)$  es el estimador por ML de  $\alpha$ .

# Estimando una Relación Poblacional

- Con lo visto anteriormente, tenemos herramientas para poder estimar la relación entre 2 variables  $Y$  y  $X$  en una población bivariada.
- En secciones anteriores vimos que cuando se tiene una población univariada, la media muestral  $\bar{Y}$  es un estimador insesgado y consistente de la media poblacional  $\mu_y$  y que es asintóticamente normal.
- Recuerde que este resultado puede ser obtenido al menos desde dos analogías: 1) la media poblacional es el mejor predictor constante de  $Y$  en la población y 2)  $\mu_y$  es el valor constante para  $c$  que minimiza  $E(U^2)$ , donde  $U = Y - c$ .

# Estimando una Relación Poblacional

- Asimismo, vimos que para estimar la proyección lineal entre dos variables de una población bivariada, era suficiente emplear los análogos muestrales de los parámetros asociados a dicha proyección, obteniéndose consistencia y normalidad asintótica.
- En este caso, la proyección lineal muestral proviene de la analogía en la muestra de minimizar  $\sum_i u_i^2/n$  donde ahora  $u_i = y_i - (a + bx_i)$ . Esto se puede entender como la analogía de los mínimos cuadrados.
- Por otro lado, el BLP es la línea que satisface  $E(U) = 0$  y  $E(XU) = 0$ . La proyección lineal en la muestra tiene las mismas propiedades pues hace  $\sum_i u_i/n = 0$  y  $\sum_i x_i u_i/n = 0$ . Esto es conocido como la analogía de **variable instrumental o de condición de ortogonalidad**.

- Con este background, ahora exploramos la estimación de  $E(Y/X) = h(X; \theta)$ , donde la función  $h(X; \theta)$  es conocida excepto por  $\theta$ .
- En particular, exploraremos los casos en los cuales  $h(X; \theta)$  es lineal y no lineal.

# Estimando una Media Condicional - El Caso Lineal

- Supongamos que la función de media condicional (CEF) es lineal pero se desconocen el intercepto y la pendiente, entonces la esperanza condicional coincide con el Mejor Predictor Lineal (BLP). Esto es:

$$E(Y/X) = \alpha + \beta X$$

con

$$\beta = \sigma_{xy} / \sigma_x^2 \quad \text{y} \quad \alpha = \mu_y - \beta \mu_x$$

Las dos analogías aplican de nuevo y el estimador natural es otra vez la proyección lineal muestral  $\hat{Y} = A + BX$ .

- En efecto, tendremos que cuando  $E(Y/X)$  es lineal,  $A$  y  $B$  son estimadores **insesgados** de  $\alpha$  y  $\beta$  como se demuestra a continuación.

- El siguiente teorema enuncia un resultado importante.

**Teorema:** En una muestra aleatoria en la cual se cumple que en la población  $E(Y/X) = \alpha + \beta X$ , el intercepto muestral A y la pendiente muestral B son estimadores insesgados de  $\alpha$  y  $\beta$ .

**Demostración:** Primero re-expresamos la varianza y la covarianza muestral de una forma más conveniente:

$$S_x^2 = (1/n) \sum_i (X_i - \bar{X})^2 = \sum_i X_i^2/n - \bar{X}^2 = (1/n) \sum_i (X_i - \bar{X})X_i$$

$$S_{xy} = \sum_i X_i Y_i/n - \bar{X}\bar{Y} = (1/n) \sum_i (X_i - \bar{X})Y_i$$

# Estimando una Media Condicional - El Caso Lineal

Además:

$$\begin{aligned} B &= S_{xy}/S_x^2 = \sum_i (X_i - \bar{X}) Y_i / \sum_i (X_i - \bar{X})^2 \\ &= \sum_i \left[ (X_i - \bar{X}) / \sum_{h=1}^n (X_h - \bar{X})^2 \right] Y_i = \sum_i W_i Y_i \end{aligned}$$

donde

$$W_i = (X_i - \bar{X}) / \sum_{h=1}^n (X_h - \bar{X})^2 \quad (i=1, \dots, n)$$

Asimismo, note que  $W_i$  satisface las siguientes propiedades:

$$\sum_i W_i = 0, \quad \sum_i W_i X_i = 1 \quad \sum_i W_i^2 = 1 / \left[ \sum_i (X_i - \bar{X})^2 \right]$$

Ahora note que  $W_i$  es una función de  $X = x = (x_1, \dots, x_n)'$ . Entonces tenemos:



## Estimando una Media Condicional - El Caso Lineal

$$\begin{aligned} E(B/x) &= E\left(\sum_i w_i Y_i/x\right) = \sum_i E(w_i Y_i/x) = \sum_i w_i E(Y_i/x) \\ &= \sum_i w_i (\alpha + \beta x_i) = \alpha \sum_i w_i + \beta \sum_i w_i x_i = \beta \end{aligned}$$

Por lo tanto,  $B$  es independiente en media de  $X$  y  $E(B) = \beta$ .  
Similarmente para  $A$ :

$$E(A/x) = E(\bar{Y}/x) - E(B/x)\bar{x} = (\alpha + \beta\bar{x}) - \beta\bar{x} = \alpha$$

Por lo tanto,  $E(A) = \alpha$ . Esto concluye la prueba.

# Estimando una Media Condicional - El Caso Lineal

- Note que durante toda la demostración anterior se utilizó que  $E(Y_i/x) = E(Y_i/x_i)$ . Esto tiene justificación mientras trabajemos en una muestra aleatoria.
- Así, es suficiente probar que  $E(Y_1/x_1, x_2) = E(Y_1/x_1)$ . Note que:

$$g(y_1/x_1, x_2) = f(y_1, x_1, x_2)/f_2(x_1, x_2)$$

y

$$f(y_1, x_1, x_2) = g_1(y_1, x_1)f_1(x_2) \quad \text{y} \quad f_2(x_1, x_2) = f_1(x_1)f_1(x_2)$$

Por lo tanto.

$$g(y_1/x_1, x_2) = g_1(y_1, x_1)/f_1(x_1) = g_2(y_1/x_1)$$

Como ambas distribuciones son iguales, entonces sus momentos son iguales. Luego tenemos que:  $E(Y_1/x_1, x_2) = E(Y_1/x_1)$

# Estimando una Media Condicional - El Caso Lineal

- En el caso de la varianza de nuestro estimador, bajo una muestra aleatoria y con CEF lineal tenemos que:

$$V(B/x) = V\left(\sum_i w_i Y_{i/x}\right) = \sum_i w_i^2 V(Y_{i/x}) = \sum_i w_i^2 V(Y_i/x_i)$$

Además, sabemos que:

$$V(B) = E_x[V(B/x)] + V[E(B/x)] = E_x[V(B/x)]$$

- Un caso particular de este resultado es aquel en el cual  $V(Y/X)$  es constante. Este caso es conocido como *homocedasticidad*.

# Estimando una Media Condicional - El Caso Lineal

- Note que en el caso de homocedasticidad, si  $V(Y/X) = \sigma^2$ , entonces:

$$V(B/x) = \sum_i w_i^2 \sigma^2 = \sigma^2 \sum_i w_i^2 = \sigma^2 / \sum_i (x_i - \bar{x})^2 = (\sigma^2/n)(1/S_x^2)$$

Entonces tenemos que:

$$V(B) = E_x[V(B/X)] = (\sigma^2/n)E(1/S_x^2)$$

Par  $n$  grande y fijo, esta varianza exacta es aproximadamente  $(\sigma^2/n)(1/\sigma_x^2)$ , la cual es en efecto la varianza asintótica de  $B$ .

- En el caso homocedástico con  $\sigma^2$  y  $E(1/S_x^2)$  desconocidos, podemos obtener un error estándar aproximado para  $B$  tomando la raíz cuadrada de

$$\hat{V}(B) = S^2/(nS_x^2)$$

con  $S^2 = \sum_i e_i^2/n$  y  $e_i = Y_i - A - BX_i$ , pues  $S^2$  y  $1/S_x^2$  son estimadores consistentes para  $\sigma^2$  y  $1/\sigma_x^2$

# Estimando una Media Condicional - El Caso No-Lineal

- La teoría precedente es aplicable también para casos en los cuales la CEF es no lineal.
- Por ejemplo, supongamos que  $E(Y/X) = \exp(\theta_1 + \theta_2 X)$  con  $\theta_1$  y  $\theta_2$  desconocidos. ¿Cómo deberíamos estimar  $\theta_1$  y  $\theta_2$ ?
- Nuevamente recurriremos a las analogías de 1) mínimos cuadrados y de 2) variables instrumentales.
- **1) Mínimos Cuadrados No-Lineales:** Sabemos que la CEF es el mejor predictor. En particular, es el mejor predictor de la forma  $h(X; c_1, c_2)$ . En la población,  $\theta_1$  y  $\theta_2$  son los valores para  $c_1$  y  $c_2$  que minimizan  $E(U^2)$ , donde:

$$U = Y - \exp(c_1 + c_2 X) = Y - h(X; c_1, c_2)$$

En la muestra tenemos entonces:

$$u_i = y_i - \exp(c_1 + c_2 x_i)$$

y escogemos  $c_1, c_2$  para minimizar  $\phi = \phi(c_1, c_2) = \sum_i u_i^2$

# Estimando una Media Condicional - El Caso No-Lineal

Sacando la CPO obtenemos:

$$\partial\phi/\partial c_1 = 2 \sum_i u_i (\partial u_i / \partial c_1) = -2 \sum_i u_i h_i$$

$$\partial\phi/\partial c_2 = 2 \sum_i u_i (\partial u_i / \partial c_2) = -2 \sum_i u_i h_i x_i$$

donde  $h_i = h(x_i; c_1, c_2)$ . Entonces tenemos:

$$\sum_i h_i u_i = 0 \quad \text{y} \quad \sum_i h_i x_i u_i = 0$$

Al estimador obtenido a partir de esto se le conoce como **Estimador por Mínimos No-Lineales (NLS)**.

- **2. Variables Instrumentales:** Las desviaciones sobre la CEF tienen media cero y covarianza cero con  $X$ . Esto es, sea  $U = Y - E(Y/X)$ , luego  $E(U) = 0$  y  $E(XU) = 0$ . Entonces estimamos  $\theta_1$  y  $\theta_2$  a través de los valores  $c_1$  y  $c_2$  que resuelven  $\sum_i u_i/n = 0$  y  $\sum_i x_i u_i/n = 0$ .
- Estas son dos ecuaciones lineales que al ser resueltas nos dan estimadores por **Variables Instrumentales** para  $\theta_1$  y  $\theta_2$ .
- Note que en este caso particular, utilizamos como instrumento a  $X$ . No obstante, podemos utilizar como instrumento a cualquier función de  $X$  por la ausencia de correlación entre  $U$  y  $X$ .

# Estimando una Media Condicional - El Caso No-Lineal

- Note que tanto para el caso de NLS como para el de IV, la computación de los estimadores obtenidos en el caso No-Lineal puede ser complicada y muchas veces se deben recurrir a métodos numéricos.
- Asimismo, las soluciones obtenidas por los estimadores IV y por NLS no siempre coinciden a pesar de que ambos son consistentes (pero no insesgados).
- Para obtener la distribución asintótica de ambos estimadores, se sigue un procedimiento similar al realizado para el estimador de Máxima Verosimilitud.
- Asimismo, note que la estimación por NLS puede ser visto como un caso particular de estimación IV, pues como el producto de las desviaciones de la CEF con cualquier función de  $X$  tiene esperanza cero, entonces NLS utiliza unas funciones en particular (instrumentos específicos).



# Un Ejemplo - Modelo Probit

- Para ilustrar los métodos de estimación estudiados antes, estudiaremos un modelo de elección binaria. Aquí  $Y$  es una variable binaria, y solo toma valores 0 y 1. En particular:

$$E(Y/X) = \Phi(\theta_1 + \theta_2 X),$$

donde  $\Phi(\cdot)$  es la cdf de la normal estándar. Además  $\phi(\cdot)$  denotará la densidad de la normal estándar.

- Vamos a considerar 3 estimadores: 1) NLS, 2) IV y 3) MV.
- En el caso de NLS, se escogen  $c_1$  y  $c_2$  que minimizan  $\sum_i u_i^2$ , donde:

$$u_i = y_i - \Phi_i, \quad \Phi_i = \Phi(c_1 + c_2 x_i)$$

# Un Ejemplo - Modelo Probit

- Luego tendremos como CPO para NLS:

$$2 \sum_i u_i (\partial u_i / \partial c_i) = -2 \sum_i u_i \phi_i,$$

$$2 \sum_i u_i (\partial u_i / \partial c_2) = -2 \sum_i u_i \phi_i x_i$$

Entonces tenemos que resolver:

$$\sum_i \phi_i u_i = 0 \quad \text{y} \quad \sum_i \phi_i x_i u_i = 0$$

# Un Ejemplo - Modelo Probit

- En el caso de estimación IV, buscamos valores  $c_1$ ,  $c_2$  que hacen  $\sum_i u_i/n = 0$  y  $\sum_i x_i u_i/n = 0$ . Entonces resolvemos:

$$\sum_i u_i = 0 \quad y \quad \sum_i x_i u_i = 0$$

Note que este sistema de ecuaciones es diferente al del NLS.

- Por último, podemos emplear también el método de MV o la regla ZES, pues conocemos la distribución condicional de  $Y$  respecto a  $X$ .
- Como  $Y$  es una variable binaria con  $E(Y/X) = \Phi(\theta_1 + \theta_2 X)$ , es claro que condicional en  $X$ ,  $Y$  tiene una distribución Bernoulli con parámetro  $F(\theta_1 + \theta_2 X)$ .
- Asimismo, como los parámetros  $\theta_1$  y  $\theta_2$  no aparecen en la distribución marginal de  $X$ , solo hay que maximizar la verosimilitud condicional. De este modo, tendremos que la función objetivo es:

# Un Ejemplo - Modelo Probit

$$L_i = y_i \log(\Phi_i) + (1 - y_i) \log(1 - \Phi_i),$$

Como tenemos 2 parámetros, tendremos 2 variables de score:

$$\begin{aligned} Z_{1i} &= \partial L_i / \partial \theta_1 = (y_i / \Phi_i) \phi_i - [(1 - y_i) / (1 - \Phi_i)] \phi_i \\ &= w_i (y_i - \Phi_i) = w_i u_i \end{aligned}$$

$$Z_{2i} = \partial L_i / \partial \theta_2 = w_i x_i (y_i - \Phi_i) = w_i x_i u_i$$

donde  $w_i = \phi_i / [\Phi_i(1 - \Phi_i)]$ . Como ambas variables score tienen esperanza cero escogemos  $c_1$  y  $c_2$  que resuelven:

$$\sum_i w_i u_i = 0 \quad \text{y} \quad \sum_i w_i x_i u_i = 0$$

Este sistema no lineal nos dará los estimadores para  $\theta_1$  y  $\theta_2$  por ML.

# Un Ejemplo - Modelo Probit

- Los tres estimadores serán diferentes en cada muestra pero todos serán consistentes (aunque no insesgados) para  $\theta_1$  y  $\theta_2$ .
- Para elegir uno de estos estimadores, podemos basarnos en la propiedad de BAN de la estimación por ML.