

# Fundamentos de Econometría

Ignacio Lobato

ITAM

- Partimos la matriz de regresores en 2:  $X = (X_1, X_2)$
- $X_1$  es de dimensión  $n \times k_1$  y  $X_2$  es de dimensión  $n \times k_2$
- De igual forma:  $b = (b'_1, b'_2)'$
- La regresión se rescribe como:

$$Y = Xb + e = (X_1 X_2) \begin{pmatrix} b_1 \\ b_2 \end{pmatrix} + e = X_1 b_1 + X_2 b_2 + e$$

- $X'_1 e = 0$  y  $X'_2 e = 0$

- Corriendo la regresión de  $y$  en  $X_1$ , el problema:

$$\min_{c_1} (Y - X_1 c_1)' (Y - X_1 c_1)$$

es de rango completo

- El vector de coeficientes es  $b_1^* = A_1 Y$  y el de residuales  $e^* = M_1 y$ , donde:

$$A_1 = (X_1' X_1)^{-1} X_1' \quad y \quad M_1 = I_n - X_1 A_1$$

$k_1 \times n$                        $n \times n$

- También se cumple que:

$$A_1 X_1 = I_{k_1}, \quad M_1 X_1 = O, \quad X_1' e^* = 0$$

- El modelo estimado es:

$$Y = X_1 b_1^* + e^*$$

- Corremos ahora la regresión de  $X_2$  en  $X_1$
- Se obtiene un conjunto de regresiones auxiliares:

$$x_j = X_1 f_j + x_j^* \quad (j = k_1 + 1, \dots, k)$$

donde  $f_j = A_1 x_j$  y  $x_j^* = M_1 x_j$

- En notación matricial:  $X_2 = X_1 F + X_2^*$
- $F = (f_{k_1+1}, \dots, f_k) = A_1 X_2$ , donde cada renglón contiene los  $k_1 \times k_2$  coeficientes de una columna de  $X_2$  en las columnas de  $X_1$
- $X_2^* = (x_{k_1+1}^*, \dots, x_k^*) = M_1 X_2$ , donde cada renglón contiene los  $n \times k_2$  residuales de la regresión anterior

- Obtenemos los coeficientes de la regresión corta:

$$b_1^* = A_1 Y = A_1 (X_1 b_1 + X_2 b_2 + e) = b_1 + F b_2$$

- Los coeficientes de la regresión corta son una combinación lineal de los coeficientes de  $X_1$  y  $X_2$  en la regresión larga
- Los residuales:

$$e^* = M_1 Y = M_1 (X_1 b_1 + X_2 b_2 + e) = X_2^* b_2 + e$$

- $e^{*'} e^* = e' e + b_2' X_2^{*'} X_2^* b_2$
- $b_2' X_2^{*'} X_2^* b_2 \geq 0$
- La suma de residuales cuadrados es mayor en la regresión corta que en la larga

- La regresión corta no puede mejorar el ajuste
- $b_2' X_2^{*'} X_2^* b_2 = 0 \Leftrightarrow X_2^* b_2 = 0 \Leftrightarrow b_2 = 0$
- La regresión corta es equivalente a la larga con la restricción de que los coeficientes de  $X_2 = 0$
- Un mínimo restringido no puede ser menor que uno no restringido
- La regresión corta difiere de la larga excepto cuando:
  - $b_2 = 0 \Rightarrow b_1^* = b_1, e^* = e$
  - $X_1' X_2 = 0 \Rightarrow F = A_1 X_2, X_2^* = X_2, b_1^* = b_1, \text{ aunque } e^* \neq e$

- Se corre la regresión de  $Y$  en  $X_2^* = M_1 X_2$ , los residuales de la regresión de  $X_2$  en  $X_1$
- El vector de coeficientes es  $c_2 = A_2^* y$ , donde:

$$A_2^* = \left( X_2^{*'} X_2^* \right)^{-1} X_2^{*'} = \left( X_2^{*'} X_2^* \right)^{-1} X_2' M_1$$

- Además:

$$M_1 Y = M_1 (X_1 b_1 + X_2 b_2 + e) = X_2^* b_2 + e$$

$$X_2' X_2^* = X_2' M_1 X_2 = X_2' M_1' M_1 X_2 = X_2^{*'} X_2^*$$

- Entonces  $c_2 = A_2^* Y = b_2$  es el subvector de  $b$  que contiene los coeficientes de  $X_2$  en la regresión larga

- $b_2$  se puede obtener en 2 pasos:
  - Correr la regresión de  $X_2$  en  $X_1$ , para obtener los residuales  $X_2^*$
  - Correr la regresión de  $Y$  en  $X_2^*$ , para obtener los coeficientes  $b_2$
- Con  $b_2$  se puede completar el vector de coeficientes  $b$  de la regresión larga:
  - Corriendo la regresión de  $Y$  en  $X_1$ , para obtener  $b_1^* = A_1 y$
  - Recuperar  $b_1 = b_1^* - F b_2$ , donde  $F = A_1 X_2$
- $c_2$  solo toma en cuenta  $X_2^*$ , el componente de  $X_2$  que no está linealmente relacionado a  $X_1$
- $c_2$  relaciona  $y$  con  $X_2$  controlando los efectos de  $X_1$



# Regresión Corta en el Modelo Clásico

- Partimos la matriz de regresores en 2:  $X = (X_1 X_2)$
- $X_1$  es de dimensión  $n \times k_1$  y  $X_2$  es de dimensión  $n \times k_2$
- $E(Y) = X_1 \beta_1 + X_2 \beta_2$
- La regresión larga se separa como:

$$Y = Xb + e = X_1 b_1 + X_2 b_2 + e$$

- Sabemos que:

$$E \begin{pmatrix} b_1 \\ b_2 \end{pmatrix} = \begin{pmatrix} \beta_1 \\ \beta_2 \end{pmatrix}, \quad V(b) = \sigma^2 Q^{-1} = \sigma^2 \begin{pmatrix} Q^{11} & Q^{12} \\ Q^{21} & Q^{22} \end{pmatrix}$$

- Si realizamos la regresión de  $Y$  en  $X_1$ , obtenemos  $b_1^* = A_1 Y$ , con:

$$E(b_1^*) = A_1 E(Y) = A_1 (X_1 \beta_1 + X_2 \beta_2) = \beta_1 + F \beta_2$$

$$V(b_1^*) = A_1 V(Y) A_1' = \sigma^2 A_1 A_1' = \sigma^2 (X_1' X_1)^{-1}$$

- Sesgo de variables omitidas: en general  $b_1^*$  es un estimador sesgado de  $\beta_1$
- Existen 2 casos en los que  $b_1^*$  es insesgado:
  - Variables omitidas irrelevantes:  $\beta_2 = 0$
  - Variables explicativas ortogonales:  $F = 0$

# Varianza de la Regresión Corta

- La varianza del modelo corto es menor que en el largo:

$$V(b_1) \geq V(b_1^*)$$

- Recordemos que:

$$b_1 = b_1^* - Fb_2$$

- Luego:

$$C(b_1^*, b_2) = A_1 V(Y) A_2^{*'} = \sigma^2 A_1 A_2^{*'}$$

- Por lo tanto:

$$V(b_1) = V(b_1^*) + FV(b_2)F'$$

- Donde  $FV(b_2)F' \geq 0$
- Existe un trade-off entre sesgo y varianza al estimar  $\beta_1$

# Residuales de la Regresión Corta

- Los residuales de la regresión corta,  $e^* = M_1 Y$  satisfacen:

$$E(e^*) = M_1 E(Y) = M_1 (X_1 \beta_1 + X_2 \beta_2) = X_2^* \beta_2$$

$$V(e^*) = M_1 V(Y) M_1' = \sigma^2 M_1$$

- En general los residuales de la regresión corta no tienen esperanza igual a cero
- La esperanza de la suma de los residuales al cuadrado es:

$$E(e^{*'} e^*) = \sigma^2 \text{tr}(M_1) + \beta_2' X_2^{*'} X_2^* \beta_2 = \sigma^2 (n - k_1) + \beta_2' X_2^{*'} X_2^* \beta_2$$

- Por lo tanto:

$$E(e^{*'} e^*) - E(e' e) = \sigma^2 k_2 + \beta_2' X_2^{*'} X_2^* \beta_2$$

- El vector de coeficientes de la regresión de  $Y$  en  $X_2^* = M_1 X_2$ ,  $c_2 = A_2^* Y = b_2$  cumple con:

$$E(b_2) = A_2^* E(Y) = A_2^* (X_1 \beta_1 + X_2 \beta_2) = \beta_2$$

$$V(b_2) = A_2^* V(Y) A_2^{*'} = \sigma^2 A_2^* A_2^{*'} = \sigma^2 (X_2^{*'} X_2^*)^{-1} = \sigma^2 (Q_{22}^*)^{-1}$$

- $b_2$  es subvector de  $b$ , entonces  $V(b_2)$  está dado por la submatriz (de  $k_2 \times 1$  dimensión  $k_2 \times k_2$  inferior derecha de  $V(b) = \sigma^2 Q^{-1}$

# Teorema de la Submatriz Inversa

- Para una matriz positiva definida  $Q$  y su inversa  $Q^{-1}$ , las partimos como:

$$Q = \begin{pmatrix} Q_{11} & Q_{12} \\ Q_{21} & Q_{22} \end{pmatrix}, \quad Q^{-1} = \begin{pmatrix} Q^{11} & Q^{12} \\ Q^{21} & Q^{22} \end{pmatrix}$$

donde las submatrices en la diagonal son cuadradas

- Entonces:

$$Q^{22} = (Q_{22}^*)^{-1}$$

donde

$$Q_{22}^* = Q_{22} - Q_{21} (Q_{11})^{-1} Q_{12}$$

# Regresión Neoclásica (supuestos)

- $E(Y|X) = X\beta$
- $V(Y|X) = \sigma^2 I$
- $X_{n \times k} = (x_1, \dots, x_k)$  es estocástica
- $\text{rango}(X) = k$

- De la estimación de mínimos cuadrados para  $\beta$ ,  $b = AY$ , y sus residuales  $e = MY$ , recordemos que:

$$E(b|X) = E(AY|X) = AE(Y|X) = AX\beta = \beta$$

$$V(b|X) = V(AY|X) = AV(Y|X)A' = \sigma^2 AA' = \sigma^2 Q^{-1}$$

$$E(e|X) = E(MY|X) = ME(Y|X) = MX\beta = 0$$

$$V(e|X) = V(MY|X) = MV(Y|X)M' = \sigma^2 M$$



- De los resultados anteriores se sigue:

$$E(e'e|X) = \sigma^2 \text{tr}(M) = \sigma^2(n - k)$$

- Como no conocemos  $\sigma^2$ , proponemos or tanto,  $\hat{\sigma}^2 = \frac{e'e}{n-k}$ , de modo que:

$$E(\hat{\sigma}^2|X) = \sigma^2$$

$$E[\hat{V}(b)|X] = E(\hat{\sigma}^2 Q^{-1}|X) = E(\hat{\sigma}^2|X) Q^{-1}$$

- Condicional en  $X$ , los estimadores  $b$ ,  $\hat{\sigma}^2$  y  $\hat{V}(b)$  son insesgados

- Utilizando la LEI con los resultados anteriores:

$$E(b) = E_X[E(b|X)] = \beta$$

$$V(b) = E_X[V(b|X)] + V_X[E(b|X)] = \sigma^2 E(Q^{-1})$$

$$E(\hat{\sigma}^2) = E_X[E(\hat{\sigma}^2|X)] = \sigma^2$$

$$E[\hat{V}(b)] = E_X\{E[\hat{V}(b)|X]\} = \sigma^2 E(Q^{-1})$$

- Los estimadores  $b$ ,  $\hat{\sigma}^2$  y  $\hat{V}(b)$  son insesgados incondicionalmente
- Para el análisis de la regresión corta:

$$E(b_1^*) = \beta_1 + E(F)\beta_2, \quad E(e^{*'}e^*) = \sigma^2(n - k_1) + \beta_2' E(Q_{22}^*) \beta_2$$

# Supuesto de Normalidad

- Ahora asumimos que la distribución de  $Y$  condicional en  $X$  se distribuye normal:

$$Y|X \sim N(X\beta, \sigma^2 I_n)$$

- Para algún coeficiente  $b_j$ :

$$b_j|X \sim N(\beta_j, \sigma^2 q^{jj})$$

- La distribución marginal de  $b_j$  no necesariamente es normal
- Sin embargo, obteniendo  $z_j = \frac{b_j - \beta_j}{\sigma \sqrt{q^{jj}}}$ :

$$z_j|X \sim N(0, 1)$$

- La distribución marginal de  $z_j$  es  $N(0, 1)$

# Ejemplo

- Para algún  $\beta_j^0$ , sea  $z_j^0 = \frac{b_j - \beta_j^0}{\sigma \sqrt{q_{jj}}}$ , si la hipótesis nula  $H_0 : \beta_j = \beta_j^0$  es verdadera:

$$P[(z_j^0 > c) | X] = P[(z_j > c) | X] = 1 - \Phi(c)$$

- La probabilidad no varía con  $X$ , por lo tanto, si  $H_0$  es verdadera:

$$P(z_j^0 > c) = 1 - \Phi(c)$$

- De igual forma para  $u_j = \frac{b_j - \beta_j}{\hat{\sigma} \sqrt{q_{jj}}}$ :

$$u_j | X \sim t(n - k)$$

para toda  $X$ , por lo que  $u_j \sim t(n - k)$

- Lo mismo aplica para los estadísticos  $\chi^2$  y  $F$
- Las distribuciones son exactas