

Fundamentos de Econometría

Ignacio Lobato

ITAM

- Ahora la función de distribución conjunta del vector $Y_{n \times 1}$ se distribuye normal
- Su función de distribución es:

$$f(Y) = (2\pi)^{-n/2} |\Sigma|^{-1/2} e^{-w/2}$$

- Donde $w = (Y - \mu)' \Sigma^{-1} (Y - \mu)$ es un escalar
- $\mu_{n \times 1}$ es un vector de medias
- $\Sigma_{n \times n}$ es una matriz positiva definida de varianzas y covarianzas

- Para una normal multivariada Y , partimos el vector en 2 subvectores Y_1 y Y_2
$$\begin{matrix} & n_1 \times 1 & & n_2 \times 1 \end{matrix}$$
- Se cumple que: $E(Y) = \mu$ y $V(Y) = \Sigma$
- La distribución marginal de Y_1 es normal: $Y_1 \sim N(\mu_1, \Sigma_{11})$, esto se cumple para Y_2 o cualquier subvector de Y
- $Y_2|Y_1 \sim N(\mu_2^*, \Sigma_{22}^*)$
 - $\mu_2^* = E(Y_2|Y_1) = \alpha + B'Y_1$
 - $B = (\Sigma_{11})^{-1} \Sigma_{12}$
 - $\alpha = \mu_2 - B'\mu_1$
 - $\Sigma_{22}^* = V(Y_2|Y_1) = \Sigma_{22} - B'\Sigma_{11}B$

- **Teorema:** para una normal multivariada, ausencia de correlación implica independencia
- Demostración:
 - Y_1 y Y_2 no están correlacionadas, entonces $\Sigma_{12} = 0$
 - Entonces $B=0$, por tanto $\mu_2^* = \alpha = \mu_2$ y $\Sigma_{22}^* = \Sigma_{22}$
 - En consecuencia $Y_2|Y_1 \sim N(\mu_2, \Sigma_{22})$ para todo Y_1
 - La distribución condicional es igual a la marginal, por lo tanto Y_1 y Y_2 son independientes

- Funciones lineales de un vector multinormal se distribuyen normal
- Para un vector multinormal Y , $z = g + HY$, se cumple:

$$z \sim N(g + H\mu, H\Sigma H')$$

- H debe ser no estocástica y de rango completo para garantizar que la matriz de varianzas y covarianzas no sea singular

Vector Normal Estándar

- Si $z_{n \times 1} \sim N(0, I)$, decimos que z es un vector normal estándar
- Si $z_{n \times 1}$ es un vector normal estándar:

$$w = z'z \sim \chi^2(n)$$

- Si $w_1 \sim \chi^2(m)$ y $w_2 \sim \chi^2(n)$ son independientes:

$$v = \frac{w_1/m}{w_2/n} \sim F(m, n)$$

- Si $z \sim N(0, 1)$ y $w \sim \chi^2(n)$ son independientes:

$$u = \frac{z}{\sqrt{w/n}} \sim t(n)$$

- Muestras grandes, $n \rightarrow \infty$
- Si $v \sim F(m, n)$, $mv \rightarrow^D \chi^2(m)$
 - Escribimos $v = \frac{w_1/m}{w_2/n}$, entonces $mv = \frac{w_1}{w_2/n}$
 - $\frac{w_2}{n} = \frac{1}{n} \sum_i z_i^2$, es una media muestral de la variable z^2 que tiene media 1
 - $\frac{w_2}{n} \rightarrow^P 1$, entonces $\frac{w_1}{1} \rightarrow^P \chi^2(m)$
- Si $u \sim t(n)$, $u \rightarrow^D N(0, 1)$
 - Escribimos $u = \frac{z}{\sqrt{(w/n)}}$
 - De la prueba anterior vimos que $\frac{w}{n} \rightarrow^P 1$, entonces u converge a la misma distribución que z

- **Teorema:** sea $Y \sim N(\mu, \Sigma)$, entonces

$$w = (Y - \mu)' \Sigma^{-1} (Y - \mu) \sim \chi^2(n)$$

- Como Σ es positiva definida, la podemos escribir como $\Sigma = C\Lambda C'$, donde Λ es diagonal con los eigenvalores de Σ y C es ortonormal con los eigenvectores de Σ como columnas
- Sea $\Lambda^* = \sqrt{\Lambda^{-1}}$
- Sea $H = C\Lambda^*C'$, entonces $H' = H$, $H'H = C\Lambda^{-1}C' = \Sigma^{-1}$ y $H\Sigma H' = I$
- Sea $\epsilon = Y - \mu$, entonces $\epsilon \sim N(0, \Sigma)$
- Por último, sea $z = H\epsilon$, entonces $z \sim N(0, I)$
- Definimos $w = \epsilon'\Sigma^{-1}\epsilon = \epsilon'H'H\epsilon = (H\epsilon)'(H\epsilon) = z'z$

- **Teorema:** sea $z_{n \times 1} \sim N(0, I)$ y $M_{n \times n}$ una matriz no estocástica de rango $r \leq n$, entonces $w = z' M z \sim \chi^2(r)$
 - Como M es simétrica e idempotente, $M = C \Lambda C'$, donde C es ortonormal y Λ es diagonal
 - Los eigenvalores de M son r 1's y $n-r$ 0's:

$$\Lambda = \begin{pmatrix} I_{r \times r} & 0_{r \times (n-r)} \\ 0_{(n-r) \times r} & 0_{(n-r) \times (n-r)} \end{pmatrix}$$

- Partimos C como $C = \begin{pmatrix} C_1 & C_2 \\ n \times r & n \times (n-r) \end{pmatrix}$
- $u_{r \times 1} = C_1' z$ multinormal con media 0 y varianza I
- $w = z' M z = z' (C_1 C_1') z = (z' C_1) (C_1' z) = u' u$

- Varios tipos de inferencia
- Dependiendo la cantidad de variables:
 - Univariada
 - Multivariada
- Dependiendo los supuestos sobre las distribuciones:
 - Aproximada
 - Exacta

- Hacemos supuestos sobre las distribuciones de la muestra
- Las distribuciones de los estadísticos estimados son exactas
- Por ejemplo, bajo el modelo clásico:

$$Y \sim^E N(X\beta, \sigma^2 I), \text{ } X \text{ no estocástica}$$

- Adicionalmente se asume que la varianza es conocida

Prueba de Hipótesis

- Univariada: se refiere a que se hace inferencia sobre un único parámetro o combinación lineal de parámetros
- $\hat{\beta}_j \sim^E N(\beta_j, \sigma^2 q_{jj})$ β_j y el ICA al 95 % para β_j es:

$$\beta_j \in \left(\hat{\beta}_j \pm 1,96\sigma\sqrt{q_{jj}} \right)$$

- Para el i-ésimo regresor, se desea probar la hipótesis $H_0 : \beta_i = \beta_i^0$ vs $H_1 : \beta_i \neq \beta_i^0$
- El estadístico es:

$$z_i^0 = (b_j - \beta_j^0) / \hat{\sigma}\sqrt{q_{jj}} \sim N(0, 1)$$

- Comparamos $|z_i^0|$ con el valor crítico de la normal correspondiente al nivel de significancia deseado
- Por ejemplo, al 95 %:
 - Si $|z_i^0| > 1.96$, se rechaza la hipótesis nula $H_0 : \beta_i = \beta_i^0$
 - Si $|z_i^0| \leq 1.96$, se acepta la hipótesis nula $H_0 : \beta_i = \beta_i^0$

- La formula para el intervalo de confianza es:

$$b_j \pm z_\alpha \hat{\sigma} \sqrt{q_{jj}}$$

- Es decir, estimación puntual $\pm z_\alpha$ (error estándar)
- Como se asumió distribución normal, el error estándar es conocido
- Si β_i^0 está dentro del intervalo de confianza, se acepta la hipótesis nula

- Ahora queremos estimar un conjunto de p restricciones lineales entre los coeficientes de β
- Por ejemplo:

$$\beta_1 = 0$$

$$\beta_2 + \beta_3 = 1$$

- En otras palabras, queremos estimar $\theta = R\beta - r$, donde H es una matriz no estocástica de rango p
- La hipótesis nula es $H_0 : \theta = 0$
- Para nuestro ejemplo: $R = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 1 \end{pmatrix}$, $r = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$

- El estadístico que se propone es:

$$w^0 = (\theta_n - \theta)' \left[\sigma^2 R (X'X)^{-1} R' \right]^{-1} (\theta_n - \theta) \sim \chi_p^2$$

- Se compara con c_p , el valor crítico superior (cola derecha) de la distribución χ^2 con p grados de libertad
- Si $w^0 > c_p$, se rechaza la hipótesis nula $H_0 : \theta = 0$
- Si $w^0 \leq c_p$, se acepta la hipótesis nula $H_0 : \theta = 0$

- Similar a los intervalos, pero ahora con múltiples dimensiones
- Ahora son regiones en \mathbb{R}^p
- La forma de la región es:

$$(\theta_n - \theta)' \left[\sigma^2 R (X'X)^{-1} R' \right]^{-1} (\theta_n - \theta) \leq c_p$$

- Si 0 cae dentro de la región, se acepta la hipótesis nula

- La potencia de la prueba se refiere a la probabilidad de rechazar una hipótesis nula como función del verdadero parámetro
- Para una prueba al 95 %, $P[(w^0 > c) | \theta] \geq ,05$ con igualdad ssi $\theta = \theta^0$
- La potencia de a prueba es mayor al nivel de significancia excepto en el valor de la hipótesis nula
- La potencia es una función creciente en la distancia entre el valor de la hipótesis θ^0 y el valor real θ

- Eliminamos el supuesto de varianza conocida
- Ahora la estimamos de forma insesgada con $\hat{\sigma}^2 = e'e / (n - k)$
- Para el caso univariado, el estadístico es:

$$\hat{z}_i = \frac{(b_i - \beta_i)}{\hat{\sigma} \sqrt{q_{ii}}}$$

- Para el caso multivariado:

$$\hat{w} = (\theta_n - \theta)' \left[p \hat{\sigma}^2 R (X'X)^{-1} R' \right]^{-1} (\theta_n - \theta)$$

- **Teorema:** $w_0 = e'e/\sigma^2 \sim \chi_{n-k}^2$
- Demostración:
 - Sea $\epsilon = Y - X\beta$, entonces $\epsilon \sim N(0, \sigma^2 I)$
 - Definimos $u = \frac{1}{\sigma}\epsilon$, entonces $\underset{n \times 1}{u} \sim N(0, I)$
 - Ahora, $Y = X\beta + \epsilon = X\beta + \sigma u$, entonces
 $e = MY = M(X\beta + \sigma u) = \sigma Mu$
 - Recordemos que M es idempotente, no estocástica y de rango $n-k$
 - Entonces $e'e = \sigma^2 u' Mu$ y $w_0 = \frac{e'e}{\sigma^2} = u' Mu \sim \chi_{n-k}^2$

- **Teorema:** $\hat{w} = (\theta_n - \theta)' \left[p \hat{\sigma}^2 R (X'X)^{-1} R' \right] (\theta_n - \theta) \sim F_{p,n-k}$
- Demostración:
 - $\frac{\hat{\sigma}^2}{\sigma^2} = [e'e / (n - k)] / \sigma^2 = (e'e / \sigma^2) / (n - k) = w_0 / (n - k)$
 - $\hat{w} / p = (w / p) / (\hat{\sigma}^2 / \sigma^2) = (w / p) / [w_0 / (n - k)]$
 - $w \sim \chi_p^2$ es independiente de $w_0 \sim \chi_{n-k}^2$

- **Teorema:** $u_i = (b_i - \beta_i) / \hat{\sigma} \sqrt{q_{ii}} \sim t_{n-k}$
- Demostración:
 - $z_i = (b_i - \beta_i) / \hat{\sigma} \sqrt{q_{ii}}$
 - $\hat{\sigma}_{bi} / \sigma_{bi} = \sqrt{(\hat{\sigma}^2 q_{ii}) / (\sigma^2 q_{ii})} = \sqrt{\hat{\sigma}^2 / \sigma^2} = \sqrt{w_0 / (n - k)}$
 - $z_i \sim N(0, 1)$ es independiente de $w_0 \sim \chi_{n-k}^2$

Intervalos de Confianza

- Seguimos utilizando la formula estimación puntual $\pm t_{\frac{\alpha}{2},(n-k)}$ error estándar:

$$b_i \pm t_{\frac{\alpha}{2},(n-k)} \hat{\sigma} \sqrt{q_{ii}}$$

- La distribución t depende del tamaño muestral
- Ahora se utiliza el valor crítico de la distribución t
- Definimos la región A como:

$$\begin{aligned} A &= \left\{ \beta_i - t_{\frac{\alpha}{2},(n-k)} \hat{\sigma} \sqrt{q_{ii}} \leq b_i \leq \beta_i + t_{\frac{\alpha}{2},(n-k)} \hat{\sigma} \sqrt{q_{ii}} \right\} \\ &= \left\{ \left| \frac{b_i - \beta_i}{\hat{\sigma} \sqrt{q_{ii}}} \right| \leq t_{\frac{\alpha}{2},(n-k)} \right\} \end{aligned}$$

- El intervalo es $P(A) = 1 - \alpha$, donde α es el nivel de significancia
- $(b_i - \beta_i) / \hat{\sigma} \sqrt{q_{ii}} \sim t_{n-k}$, entonces $c = t_{\alpha/2}$
- En una prueba de hipótesis, si el valor de la hipótesis nula $\beta_i = \beta_i^0$ cae dentro del intervalo, se acepta

- Similar que el intervalo, pero ahora para un vector $\theta_{p \times 1} = R\beta - r$ de parámetros
- La región queda dada por:

$$(\theta_n - \theta)' \frac{[pR(X'X)^{-1}R']^{-1}}{\hat{\sigma}^2} (\theta_n - \theta) \leq F_{p,n-k}$$

- d se obtiene de la distribución $F_{p,n-k}$
- Si 0 cae dentro de la región, se acepta la hipótesis nula

- Ahora relajaremos los supuestos que hemos hecho sobre la distribución de la muestra
- En la práctica no se conocen las distribuciones
- Los resultados ya no son exactos
- Nos basaremos ahora en propiedades asintóticas para obtener las distribuciones aproximadas

- Eliminamos el supuesto de normalidad
- Utilizamos el mismo estimador $\hat{\theta} = Rb - r$
- Nuestro estadístico para la prueba de hipótesis ahora es:

$$W_n = (Rb - r)' \left[\tilde{\sigma}_n^2 R (X'X)^{-1} R' \right]^{-1} (Rb - r)$$

- $\tilde{\sigma}_n^2 = \frac{e'e}{n}$, la estimación de la varianza ahora no tiene que ser insesgada, basta que sea consistente
- $W_n \rightarrow^D \chi_p^2$, la distribución ahora es aproximada

- Definimos los residuales de la regresión bajo la hipótesis nula como $e^{*'}e^*$
- Una manera alternativa de escribir el estadístico de Wald es:

$$F_n = \frac{e^{*'}e^* - e'e}{pe'e} = \frac{\sigma^{*2} - \tilde{\sigma}^2}{p\sigma^2} \rightarrow_D \frac{\chi_p^2}{p}$$

- Nuevamente, la distribución es aproximada
- Cuando n es grande, inferencia exacta e inferencia aproximada llevan a resultados similares