

$$\begin{aligned} \mathcal{L}(\theta; \mathbf{x}) &= \theta \\ \mathcal{L}(\theta; \mathbf{x}) &= \hat{\mu} = \bar{x} \\ \frac{\partial \mathcal{L}}{\partial \theta} = 0 &\Rightarrow \hat{\theta}_{MV} \end{aligned} \quad \begin{aligned} X_i &\sim \mathcal{N}(\mu, \sigma^2) \\ \hat{\mu} &= \bar{x} \\ \hat{\sigma}^2 &= \frac{1}{n} \sum (X_i - \bar{x})^2 \end{aligned}$$

Propiedad de invarianza
 $\theta \rightarrow \hat{\theta}$
 $g(\theta) \rightarrow g(\hat{\theta})$

Ejemplo

$X_1, \dots, X_n \stackrel{iid}{\sim} U(0, \theta)$. Calcular el EMV de θ .

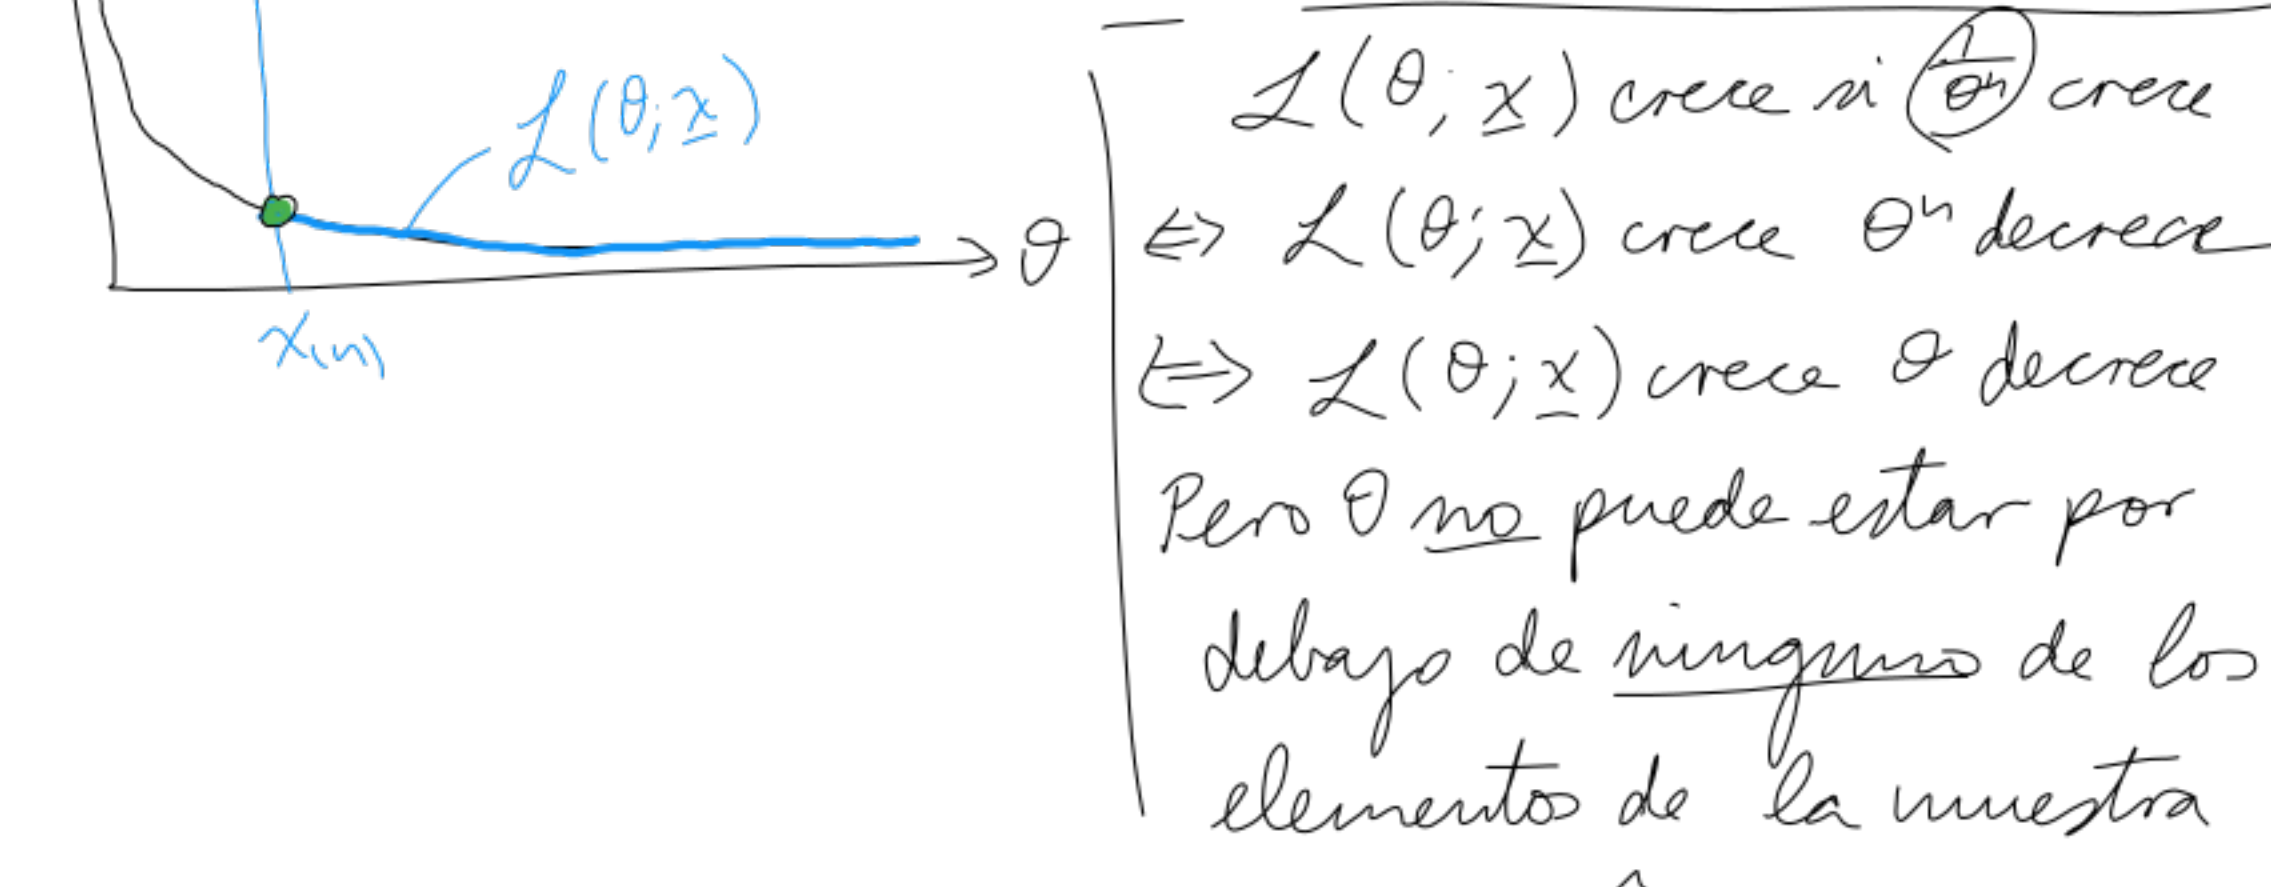
$$\begin{aligned} f_X(x; \theta) &= \frac{1}{\theta} I_{(0, \theta)}(x) \\ \mathcal{L}(\theta; \mathbf{x}) &= \prod_{i=1}^n \frac{1}{\theta} I_{(0, \theta)}(x_i) \\ &= \left(\frac{1}{\theta^n}\right) I_{(x_{(n)}, \infty)}(\theta) \end{aligned}$$

$0 < x < \theta$
 y para una muestra
 $0 < x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)} < \theta < \infty$

$$\ell(\theta; \mathbf{x}) = -n \log(\theta)$$

$$\frac{\partial \ell}{\partial \theta} = -\frac{n}{\theta} \equiv 0 \Leftrightarrow n=0$$


El EMV no se puede obtener derivando \mathcal{L} o ℓ



Ejemplo (Caso Pareto)

$X \sim \text{Pareto}(x_m, \alpha)$ $x_m > 0, \alpha > 0$ y $x_m < x < \infty$

$$f_X(x; x_m, \alpha) = \frac{\alpha x_m^\alpha}{x^{\alpha+1}} I_{(x_m, \infty)}(x)$$



$$X \sim \text{Pa}(x_m, \alpha) \Rightarrow Y = \log\left(\frac{X}{x_m}\right) \sim \text{Exp}(\alpha)$$

Calcular el EMV de x_m y α .

$$\begin{aligned} \mathcal{L}(x_m, \alpha; \mathbf{x}) &= \prod_{i=1}^n \frac{\alpha x_m^\alpha}{x_i^{\alpha+1}} I_{(x_m, \infty)}(x_i) \\ &= \alpha^n x_m^{n\alpha} e^{-(\alpha+1) \sum \log(x_i)} \cdot I_{\mathbb{R}^+}(\alpha) \cdot I_{(0, x_{(1)})}(x_m) \end{aligned}$$

$\prod_{i=1}^n x_i^{-(\alpha+1)} = e^{\log\left(\prod_{i=1}^n x_i^{-(\alpha+1)}\right)} = e^{-\sum \log(x_i^{-(\alpha+1)})} = e^{-(\alpha+1) \sum \log(x_i)}$

$U: 0 < x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)} < \theta$
 $P: 0 < x_m < x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$

$$\ell(x_m, \alpha; \mathbf{x}) = n \log(\alpha) + n\alpha \log(x_m) - (\alpha+1) \sum \log(x_i)$$

Caso para x_m :


$$\frac{\partial \ell}{\partial x_m} = \frac{n\alpha}{x_m} \equiv 0 \Leftrightarrow n\alpha = 0 \Leftrightarrow n=0$$

(No es posible obtener el EMV de x_m derivando)

Recordemos que $0 < x_m < x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$

$$\mathcal{L}(x_m, \alpha; \mathbf{x}) = \alpha^n e^{-(\alpha+1) \sum \log(x_i)} x_m^{n\alpha} = c x_m^{n\alpha}$$

constante respecto a x_m



Caso para α :

$$\begin{aligned} \frac{\partial \ell}{\partial \alpha} &= \frac{n}{\alpha} + n \log(x_m) - \sum \log(x_i) \equiv 0 \\ \Leftrightarrow \frac{n}{\alpha} &= \sum \log(x_i) - n \log(x_m) \\ \Leftrightarrow \alpha &= \frac{n}{\sum \log(x_i) - n \log(x_m)} \end{aligned}$$

Como x_m es desconocido, entonces por la propiedad de invarianza de los estimadores,

$$\therefore \hat{\alpha}_{MV} = \frac{n}{\sum \log(x_i) - n \log(x_{(1)})}$$

Ejemplo (Caso "pequeño")

Sea X una v.a. tal que para $\theta \in [0, 1]$

x	0	1	2	3
$P(X=x)$	$\frac{2\theta}{3}$	$\frac{\theta}{3}$	$\frac{2(1-\theta)}{3}$	$\frac{1-\theta}{3}$

Encontrar el EMV de θ .

$$\begin{aligned} \mathcal{L}(\theta; \mathbf{x}) &= \prod_{i=1}^n P(X=x_i) \\ &= P(X=0)P(X=1)P(X=2)P(X=3) \\ &= \frac{2\theta}{3} \cdot \frac{\theta}{3} \cdot \frac{2(1-\theta)}{3} \cdot \frac{1-\theta}{3} \\ &= \frac{4\theta^2(1-\theta)^2}{81} \end{aligned}$$

$$\begin{aligned} \ell(\theta; \mathbf{x}) &= \log(4) + 2\log(\theta) + 2\log(1-\theta) - \log(81) \\ \frac{\partial \ell}{\partial \theta} &= \frac{2}{\theta} + \frac{2}{1-\theta}(-1) = \frac{2}{\theta} - \frac{2}{1-\theta} \equiv 0 \\ \Leftrightarrow \frac{2}{\theta} &= \frac{2}{1-\theta} \Leftrightarrow \frac{\theta}{2} = \frac{1-\theta}{2} \\ \Leftrightarrow 1-\theta &= \theta \Leftrightarrow 2\theta = 1 \Leftrightarrow \theta = \frac{1}{2} \\ \therefore \hat{\theta}_{MV} &= \frac{1}{2} + 0X_1 + 0X_2 + \dots + 0X_n \\ &= \frac{1}{2} \end{aligned}$$

Propiedades de los estimadores

Hemos visto hasta ahora una técnica para obtener estimadores. Sin embargo, este no es el único objetivo. También queremos validar que tan "buenos" son.

Recordemos que un estimador es una función de la muestra, por lo que, antes de que ésta sea observada, $\hat{\theta} = h(\mathbf{X})$ es una v.a. Por esto es razonable pensar en $E[\hat{\theta}]$ y $V(\hat{\theta})$.

Propiedad 1: sesgo

Def. Sea X_1, \dots, X_n una m.a. con f.d.p. $f_X(x; \theta)$ donde θ es el parámetro de interés y $\hat{\theta} = h(X_1, \dots, X_n)$ un estimador de θ (¡no tiene que ser el EMV de θ !). Definimos el **sesgo** o **error de estimación promedio** de $\hat{\theta}$ como

$$\text{Bias}(\hat{\theta}) = B(\hat{\theta}) = E[\hat{\theta}] - \theta$$

Comentarios:

- $B(\hat{\theta}) = 0 \Leftrightarrow E[\hat{\theta}] = \theta$
- Si se cumple que $B(\hat{\theta}) = 0$, decimos que $\hat{\theta}$ es **insesgado**.
- Propiedad **DESEABLE** pero no suficiente

Ejemplo $\hat{\sigma}_{MV}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$ ← sesgado

vs

$s^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$ ← insesgado

Vamos a demostrar que s^2 es insesgado, es decir $E[s^2] = \sigma^2$

$$\begin{aligned} \rightarrow E[(n-1)s^2] &= E\left[\sum (X_i - \bar{X})^2\right] \\ &= E\left[\sum (X_i^2 - 2\bar{X}X_i + \bar{X}^2)\right] \\ &= E\left[\sum X_i^2 - 2\bar{X} \sum X_i + \sum \bar{X}^2\right] \\ &= E\left[\sum X_i^2 - 2\bar{X} \sum X_i + n\bar{X}^2\right] \\ &= E\left[\sum X_i^2 - 2\bar{X}(n\bar{X}) + n\bar{X}^2\right] \\ &= E\left[\sum X_i^2 - 2n\bar{X}^2 + n\bar{X}^2\right] \\ &= E\left[\sum X_i^2 - n\bar{X}^2\right] \\ &= \sum E[X_i^2] - nE[\bar{X}^2] = (*) \end{aligned}$$

Recordemos que si $X_i \sim \mathcal{N}(\mu, \sigma^2)$, entonces

$$E[X_i^2] = V(X_i) + E^2[X_i] = \sigma^2 + \mu^2$$

y si $\bar{X} \sim \mathcal{N}(\mu, \frac{\sigma^2}{n})$, entonces

$$E[\bar{X}^2] = V(\bar{X}) + E^2[\bar{X}] = \frac{\sigma^2}{n} + \mu^2$$

$$\begin{aligned} \Rightarrow (*) &= \sum (\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right) \\ &= n\sigma^2 + n\mu^2 - \sigma^2 - n\mu^2 \\ &= n\sigma^2 - \sigma^2 \\ &= (n-1)\sigma^2 \end{aligned}$$

$$\therefore E[(n-1)s^2] = (n-1)\sigma^2$$

$$\Leftrightarrow \cancel{(n-1)} E[s^2] = \cancel{(n-1)} \sigma^2$$

$$E[s^2] = \sigma^2$$

$\therefore s^2$ es insesgado

$$E[n\hat{\sigma}_{MV}^2] = (n-1)\sigma^2$$

$$E[\hat{\sigma}_{MV}^2] = \frac{n-1}{n} \sigma^2 \neq \sigma^2$$

$\therefore \hat{\sigma}_{MV}^2$ tiene sesgo